可解释深度迁移学习用于乳腺超声癌症检测：多数据集研究

Interpretable Deep Transfer Learning for Breast Ultrasound Cancer Detection: A Multi-Dataset Study

作者： Mohammad Abbadi, Yassine Himeur, Shadi Atalla, Wathiq Mansoor

单位： 迪拜大学工程与信息技术学院

翻译版本： 中文译本

摘要

乳腺癌仍是全球女性癌症相关死亡的主要原因。超声成像因其安全性和成本效益而被广泛应用，在早期检测中发挥着关键作用，尤其对于乳腺组织致密的患者。本文对机器学习和深度学习技术在乳腺超声图像癌症分类中的应用进行了全面研究。使用BUSI、BUS-BRA和BrEaST-Lesions USG等数据集，我们评估了经典机器学习模型（SVM、KNN）和深度卷积神经网络（ResNet-18、EfficientNet-B0、GoogLeNet）。实验结果表明，ResNet-18达到了最高的准确率（99.7%）和对恶性病变的完美敏感性。经典机器学习模型虽然被CNN超越，但在结合深度特征提取后表现出具有竞争力的性能。Grad-CAM可视化通过突出显示诊断相关图像区域进一步提高了模型透明度。这些发现支持将基于AI的诊断工具整合到临床工作流程中，并证明了部署高性能、可解释系统进行超声乳腺癌检测的可行性。

关键词： 乳腺癌，超声成像，机器学习，深度学习，影像组学，结构化数据，人工智能，可解释性，计算机辅助诊断

I. 引言

乳腺癌是全球女性中最常诊断的癌症，仅2020年就报告了超过230万新发病例和68.5万死亡病例[1][2]。它仍然是癌症相关死亡的主要原因，特别是在筛查项目可及性有限的中低收入国家。乳腺癌的早期检测至关重要，因为它能显著改善治疗效果和生存率[3][4]。医学影像在筛查和诊断路径中发挥着关键作用，根据患者风险特征和乳腺密度，乳腺X线摄影、超声和MRI等成像方式被广泛应用[5]。

在这些成像方式中，超声成像以其实时成像能力、经济性、无电离辐射以及对致密乳腺组织评估的有效性而脱颖而出[6][7]。超声常用于区分实性肿块和囊性肿块、表征可疑病变以及引导活检。然而，超声图像的解释高度依赖操作者，且容易产生变异性，特别是在区分具有细微视觉差异的良性和恶性病变时[8][9]。这产生了对计算机辅助诊断（CAD）系统的强烈需求，该系统可以协助临床医生一致且准确地解释超声检查结果[10]。

人工智能（AI）和机器学习（ML）的最新进展为使用超声增强乳腺癌检测的诊断准确性开辟了新途径。经典机器学习方法——如支持向量机（SVM）、决策树和k近邻（KNN）——历史上依赖于从病变区域提取的手工特征，如纹理、形状和强度描述符。虽然这些方法在一定程度上有效，但往往存在泛化能力有限的问题，且需要专家驱动的特征工程[11]。

随着深度学习的兴起，特别是卷积神经网络（CNN），乳腺超声图像的癌症检测在敏感性、特异性和整体诊断性能方面取得了显著改善。例如，Zhang等人（2021）[12][13]证明CNN在区分恶性病变方面可达到92%的敏感性。Liu等人（2022）[14]提出了一种将CNN提取的特征与经典分类器相结合的混合方法，达到了94%的准确率。同样，Patel等人（2021）[15]使用迁移学习来提升有限数据集上的性能，达到了93.5%的准确率。更新的发展将注意力机制整合到CNN架构中以聚焦于病变特定区域。例如，Kim等人（2023）[16]引入了一种注意力CNN模型，在提高可解释性的同时将分类精度比标准CNN提高了5%。

比较分析还突出了不同AI模型的相对优势和劣势。Wang等人（2023）[17]报告集成方法如随机森林和梯度提升树在鲁棒性和泛化能力方面优于独立ML算法。Sun等人（2022）[18]比较了深度学习模型与经典ML技术，发现虽然深度学习产生更优的准确率，但需要更多的数据、计算能力和模型可解释性。在一项多中心研究中，Xiang等人（2023）[19]在多个临床站点验证了一个深度学习模型，达到了0.94-0.96的曲线下面积（AUC），从而强化了外部验证对于实际部署的重要性。

同样重要的是AI工具的可解释性及其整合到临床工作流程中。Yan等人（2024）[20]表明可解释AI模型可以提高放射科医生的诊断信心。同时，Liu等人（2024）[21]提出了一个深度影像组学框架，将基于CNN的图像特征与临床元数据整合，达到了0.888的AUC，优于传统的基于影像组学的分类器。

尽管取得了这些进展，关键挑战仍然存在——特别是大型、标注良好且多样化的超声数据集的稀缺性；深度学习模型的有限可解释性；以及前瞻性临床验证的需求[22][23]。本研究通过利用多个开源超声图像数据集、比较经典ML模型与现代深度学习架构，并提出了一个兼顾性能和临床可行性的平衡诊断框架，为该领域做出了贡献。本研究的主要贡献总结如下：

1. 针对BUSI、BUS-BRA、BrEaST-Lesions USG及额外档案的超声乳腺癌分类综合多数据集基准，实现稳健的跨源评估。
2. 统一、可复现的流水线——归一化、散斑噪声降低、ROI裁剪和增强——结合VGG16、AlexNet、ResNet-18、GoogLeNet和EfficientNet-B0的迁移学习。
3. 经典ML（SVM、KNN）与CNN的系统头对头比较，显示深度特征迁移将SVM/KNN提升到接近CNN的性能。
4. 最先进的结果：ResNet-18达到99.7%的准确率和完美的恶性召回率；EfficientNet-B0以更低延迟提供有竞争力的准确率。
5. 通过Grad-CAM突出显示诊断相关区域的内置可解释性，支持临床信任。
6. 外部验证（95.2%准确率）证明泛化能力并阐明域偏移差距。
7. 优先考虑恶性召回和AUC的明确模型选择标准，以及便于在临床工作流程中复制和部署的显式算法表述。

II. 材料与方法

A. 数据集

本研究使用了五个公开可用的乳腺超声成像数据集，以确保对机器学习和深度学习模型在乳腺癌检测中的多样化和代表性评估：

1. **乳腺超声图像数据集（BUSI）**[24]：该数据集包含来自600名女性患者的780张灰度乳腺超声图像，标注为正常、良性或恶性。每张图像都配有突出显示病变区域的二值掩码。
2. **BUS-BRA数据集**[25]：包含来自1,064名患者的1,875张图像，提供BI-RADS标签和活检证实的真实标签。它涵盖多个超声扫描仪和采集设置，具有预定义的数据分割以确保可复现性。
3. **BrEaST-Lesions USG图像和掩码**：该集合专注于具有高质量专家勾画掩码的病变分割。它支持分类和定位任务，特别是在小病变场景中。
4. **乳腺超声图像档案**：来自公共学术存储库，该数据集包含带有良性/恶性标签的超声图像。它引入了有助于泛化测试的采集变异性。
5. **混合数据集**：通过混合上述数据集的样本并应用增强来包含罕见病变类型而组装。这个复合数据集有助于测试分布外泛化。

在本研究中，我们确实讨论了五个数据集（BUSI、BUS-BRA、BrEaST-Lesions USG、乳腺超声档案和混合数据集）。然而，本文呈现的结果专门来自BUSI和BUS-BRA数据集上的实验。选择这两个数据集是因为它们是广泛使用的基准，具有足够的规模和一致的注释，用于评估经典机器学习和深度学习模型。其他数据集（BrEaST-Lesions USG、乳腺超声档案和混合数据集）主要用于分割、增强和外部验证/泛化测试。例如，我们在来自另一个档案的100张图像的外部集上验证了最佳性能模型（ResNet-18），达到了95.2%的准确率，确认了强大的泛化能力，但也突出了域偏移的挑战。因此，虽然论文提出了多数据集框架，但主要结果是数据集特定的（BUSI和BUS-BRA），额外数据集用于确保鲁棒性和分布外评估。

B. 预处理技术

在模型训练之前，所有图像都被转换为标准化格式。我们首先应用灰度归一化，将像素强度重新缩放到[0,1]范围，然后使用3×3中值滤波器进行散斑噪声降低，以抑制超声伪影同时保留病变边界。然后将图像调整为224×224或227×227以匹配深度学习模型的输入维度。当分割掩码可用时（例如BUSI），我们执行ROI提取以获得病变中心裁剪。最后，为了改善泛化，我们在训练期间使用数据增强，应用随机水平/垂直翻转、±10°旋转和高达10%的缩放。

C. 特征提取

特征提取遵循两种互补策略。首先，我们计算适合经典ML的手工特征，包括形状描述符（紧凑度、伸长率、纵横比）、基于GLCM的纹理指标（对比度、熵、相关性）和强度直方图；结果向量使用最小-最大缩放进行归一化。其次，我们从预训练CNN（例如VGG16、ResNet-18）的中间层或最终层提取嵌入来推导深度特征；这些512-4096维表示随后被用作下游分类器（如SVM和KNN）的输入。

D. 模型架构

1) 经典机器学习模型：我们采用了两个经典模型：具有线性和RBF核的支持向量机（SVM），其中超参数C和γ通过网格搜索调整；以及k近邻（KNN）分类器，使用欧几里得距离对$k \in \{1, ..., 10\}$进行评估，最优k通过5折交叉验证选择。两个模型都使用手工特征和深度特征输入进行训练和比较。

2) 深度学习模型：以下CNN架构使用迁移学习实现：

- **VGG16和AlexNet：**用于初始基准测试的浅层网络。
- **ResNet18和GoogLeNet：**具有跳跃连接或Inception模块的深层网络，使用Adam优化器（学习率：10^{-4}）进行微调。
- **EfficientNet-B0：**用于平衡准确率和推理速度的轻量级但高性能模型[26]。

所有CNN模型都训练20-50个epoch，并根据验证损失进行早停。分类交叉熵被用作损失函数。

E. 评估指标

模型性能使用以下指标评估：

- **准确率：**正确预测样本的比例。
- **精确率：**TP/(TP+FP)，表示阳性预测的可靠性。
- **召回率（敏感性）：**TP/(TP+FN)，表示模型检测恶性病例的能力。
- **F1分数：**精确率和召回率的调和平均值。
- **AUC-ROC：**受试者工作特征曲线下面积，对于不平衡数据集特别有用。

使用交叉验证（5折）确保模型泛化。对于CNN，使用80%-10%-10%的训练-验证-测试分割，除非数据集提供官方分割（例如BUS-BRA）。

III. 结果

A. 性能比较

我们的实验评估了经典机器学习分类器和深度学习架构在乳腺超声图像癌症分类中的表现。表I总结了BUSI和BUS-BRA数据集上各模型的结果。

表I 传统ML和DL模型的性能指标（3类：正常、良性、恶性）

模型	准确率(%)	精确率	召回率	F1	AUC
SVM（手工特征）	88.3	0.85	0.84	0.84	0.89
KNN（手工特征）	86.1	0.83	0.82	0.82	0.87
SVM（深度特征）	99.3	0.99	0.99	0.99	0.996
KNN（深度特征）	98.9	0.98	0.99	0.98	0.995
AlexNet	98.3	0.98	0.97	0.97	0.981
GoogLeNet	99.6	0.99	0.99	0.99	0.997
ResNet-18	99.7	0.99	1.00	0.995	0.998
EfficientNet-B0	99.5	0.99	0.99	0.99	0.997

B. 分析

结果表明：

- ResNet-18达到了最高的准确率（99.7%）和对恶性病例的完美召回率，使其成为临床应用的最佳候选。
- 使用手工特征的经典ML模型表现显著低于深度学习对应模型。
- 当使用预训练CNN的深度特征时，SVM和KNN的性能大幅提升（从88%到99%），与Jabeen等人[27]的发现一致。
- GoogLeNet和EfficientNet-B0以更快的推理时间提供高准确率，表明适合实时系统。

C. 外部验证

为了评估泛化能力，我们在来自不同开放获取档案的100张图像外部集上评估了表现最佳的模型（ResNet-18）。模型保持了95.2%的准确率，大多数错误发生在非常小或模糊的病变病例中。这

强化了其鲁棒性，但也突出了多样化训练数据的需求。这个外部集未用于训练或模型选择，仅用于探测分布外泛化。

D. 混淆矩阵和可视化

图1展示了ResNet-18在测试集上的混淆矩阵。模型仅犯了一个错误分类（良性病例被预测为恶性），没有遗漏恶性病变。图2显示了比较不同模型的ROC曲线。所有CNN的AUC都超过0.98。

[图1：ResNet-18在3类分类上的混淆矩阵]

图1 ResNet-18在3类分类上的混淆矩阵

[图2：所选模型的ROC曲线]

图2 所选模型的ROC曲线

这些结果表明，通过适当的架构、预处理和数据集多样性，AI系统可以达到或超过专家级别的超声乳腺癌检测准确率。

算法1：具有数学公式的超声乳腺癌检测

输入： 标注数据集 $D = \{(x_i, y_i)\}_{i=1}^{N}$，$y_i \in \{0,1,2\}$（正常、良性、恶性）；掩码 $\{M_i\}$（当可用时）；CNN主干网络 M；ML模型 $\{SVM, KNN\}$。

输出： 最佳模型 M^*，指标（准确率、精确率、召回率、F1、AUC），Grad-CAM图。

1. 分割与符号：

分割 $D \to D_{train}, D_{val}, D_{test}$（分层80/10/10或官方分割）。

令 $Y = \{0,1,2\}$，独热标签 $e_{y_i} \in \{0,1\}^3$。

2. 预处理：

归一化（最小-最大）：$x'_i = (x_i - \min(x_i))/(\max(x_i) - \min(x_i)) \in [0,1]$

散斑降低：$\tilde{x}_i = M_{3\times3}(x'_i)$（中值算子）

调整大小：$\bar{x}_i = R_{224\times224}(\tilde{x}_i)$

ROI（如果有掩码）：$x_{roi,i} = \mathrm{Crop}(\bar{x}_i \odot M_i)$；否则 $x_{roi,i} = \bar{x}_i$

增强（训练）：$\{x_i^{(k)} = T_k(x_{roi,i})\}_{k=1}^{K}$，旋转±10°、翻转、缩放≤10%

3. 特征提取：

手工特征：$\varphi_h(x) = [$形状, GLCM（对比度、熵、相关性）, 强度直方图$]$，缩放 $\varphi_h \leftarrow \mathrm{MinMax}(\varphi_h)$

深度特征：对于 $g_\theta \in M$，嵌入 $z_i = g_\theta^{penul}(x_{roi,i}) \in R^d$

4. 经典ML训练：

SVM（核k）：求解 $\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_i \xi_i$，约束 $y'_i(w^T\Phi(x_i)+b) \geq 1-\xi_i$, $\xi_i \geq 0$

KNN（加权）：对于测试x，预测 $\hat{y} = \arg\max_{c\in Y} \sum_{j\in N_k(x)} w_j 1[y_j=c]$, $w_j = 1/(\|x-x_j\|^2+\varepsilon)$

使用(i)φ_h和(ii)深度z进行训练/评估；通过5折CV调整C、γ、k

5. 深度学习（迁移学习）：

用预训练 θ_0 初始化 f_θ；将头部替换为3路分类器。优化 $\min_\theta L(\theta) = (1/|B|)\sum_{(x,y)\in B} \mathrm{CE}(\mathrm{softmax}(f_\theta(x)), e_y) + \lambda\|\theta-\theta_0\|^2$

使用Adam（$lr=10^{-4}$），在验证损失上进行早停。如果平台期则渐进解冻。

6. 评估（测试）：

对于每类c的混淆计数（TP_c, FP_c, FN_c, TN_c）：

$Acc = \sum_c(TP_c+TN_c)/\sum_c(TP_c+FP_c+FN_c+TN_c)$

$Prec_c = TP_c/(TP_c+FP_c)$, $Rec_c = TP_c/(TP_c+FN_c)$

$F1_c = 2Prec_c \cdot Rec_c/(Prec_c+Rec_c)$

$AUC = \sum_t(TPR(t)+TPR(t+1))/2\cdot(FPR(t+1)-FPR(t))$

使用宏平均；突出显示恶性召回率。

7. 可解释性（Grad-CAM）：

令A_k为最后卷积层的第k个激活图，s_c为类c的预softmax分数。权重：$\alpha_k^c = (1/Z)\sum_{u,v}(\partial s_c/\partial A_{uv}^k)$

$L_{Grad\text{-}CAM}^c = \mathrm{ReLU}(\sum_k \alpha_k^c A_k)$

在输入上叠加$L_{Grad\text{-}CAM}^c$；验证临床对齐。

8. 模型选择：

选择$M = \arg\max_M(Rec_{malig}(M), AUC(M), Acc(M))$，优先考虑恶性召回率，然后是AUC。通过跨折方差和延迟打破平局。

9. 外部验证：

在外部集D_{ext}上评估M；按步骤6报告指标。分析错误；记录域偏移指标（例如$\Delta\mu = \|E_{train}[z]-E_{ext}[z]\|_2$）。

10. 交付物：

```
提供最佳权重θ*、预处理P、特征提取器g_θ*、推理脚本和产物（ROC、混淆矩阵、Grad-CAM面板）。
```

IV. 讨论

本研究获得的结果表明，机器学习，特别是深度学习模型，可以在乳腺超声图像分类中达到专家级别的准确率。表现最佳的模型ResNet-18达到了99.7%的分类准确率，对恶性病变具有完美的敏感性。这些指标表明将基于AI的系统整合到临床工作流程中具有强大潜力，特别是作为辅助放射科医生早期癌症检测的第二阅读器工具。

A. 临床意义

恶性病变检测中观察到的高敏感性在临床环境中尤为重要，因为假阴性的代价可能很严重。一个可靠标记可疑病例的系统确保患者及时接受后续检查和活检。相反，高特异性减少了良性病例的不必要干预，有助于避免过度诊断和过度治疗。这些能力在资源有限或高吞吐量的环境中特别有影响，如公共筛查诊所，放射科医生的时间受到限制。

此外，由于超声成像无电离辐射、广泛可用且成本效益高，AI辅助超声CAD系统可以在乳腺X线筛查基础设施稀少的中低收入地区发挥变革性作用。正如我们的结果所证明的，将深度特征与经典分类器（例如SVM）相结合也提供了高性能，同时需要较低的计算资源，使此类系统甚至可以在中端硬件上部署。

B. 可解释性和可解释性

临床AI采用的主要关注点之一是深度学习的"黑箱"性质。为了解决这个问题，我们整合了Grad-CAM等可解释性工具来可视化影响每个预测的显著区域。这些可视化不仅增强了放射科医生对模型决策的信任，还提供了关于模型是否在学习医学相关模式的洞察——如不规则边缘、后方声影或高回声晕——这些通常与恶性相关。

最近文献强调，可解释AI改善决策信心，更有可能被接受进入临床工作流程[20][28]。我们的发现支持这一观点：Grad-CAM叠加层经常与肿瘤区域对齐，在错误分类的病例中，可视化通常揭示了即使对专家放射科医生也具有挑战性的模糊边界。

C. 局限性

尽管结果令人鼓舞，但必须承认几个局限性。首先，使用的大多数数据集——如BUSI和BUS-BRA——由具有注释掩码的精心策划的图像组成，这可能无法完全反映现实世界的变异性。临床环境中的图像质量、伪影的存在以及扫描仪差异可能影响模型的泛化能力。

其次，本研究仅关注分类（正常vs良性vs恶性），并假设病变区域是已知的或容易提取的。然而，实时部署需要一个能够同时进行病变定位和分类的端到端框架。目标检测模型如YOLOv5或Faster R-CNN可以在未来工作中探索以满足这一需求[29]。

第三，虽然Grad-CAM在产生类激活图方面有效，但并不总是提供细粒度或病例特定的推理。未来工作应考虑模型无关的可解释性技术，如LIME或SHAP，它们可以提供超出空间热图的特征级解释。

D. 泛化和验证

为了评估现实世界的适用性，我们在包含未见超声图像的外部数据集上测试了我们的ResNet-18模型。虽然准确率略微下降到95.2%，但模型保持了对恶性病例的高召回率。这表明强大的泛化能力，但在临床部署之前，更广泛的多中心验证是必不可少的。先前的工作表明，除非使用域适应或联邦学习，否则模型性能在跨机构或人口群体应用时往往会下降[19][30]。

E. 贡献与未来工作

我们的工作为越来越多的研究做出了贡献，这些研究表明AI系统不仅可以匹敌，有时甚至可以在适当训练时超越传统诊断工具。与先前仅依赖一种算法类型的研究不同，我们的方法在经典机器学习模型（例如SVM、KNN）和深度CNN架构（例如ResNet、EfficientNet）之间提供了全面比较，从而基于硬件和临床约束在系统设计中提供了灵活性。

在未来的研究中，我们旨在：

- 使用目标检测框架整合病变检测模块。
- 探索多模态数据融合（例如将超声与临床元数据结合）。
- 在多中心数据集上验证模型，包括便携式超声设备。
- 实施可在资源有限环境中部署的实时诊断支持工具。

最终，为了让AI获得广泛的临床采用，它必须不仅展示性能优越性，还要展示透明度、泛化能力和与现有诊断路径的无缝整合。

V. 结论

在本研究中，使用机器学习和深度学习在公开可用数据集（特别是BUSI和BUS-BRA）上评估了基于超声的乳腺癌检测。经典分类器（SVM、KNN）与迁移学习CNN（ResNet-18、EfficientNet-B0）进行了系统比较。深度模型明显优于传统方法；ResNet-18达到了99.7%的准确率和完美的恶性召回率。结果证实了AI工具以高敏感性和精确性辅助放射科医生的可行性。通过Grad-CAM的可解释性突出了诊断相关区域，加强了临床信任。尽管如此，现实世界的部署需要多中心验证、整合病变定位以及仔细评估跨扫描仪和患者人口统计学的泛化能力。未来工作针对端到端诊断流水

线、多模态融合和前瞻性评估。总体而言，该研究强调了临床导向、可解释AI的重要性，并将超声定位为改善早期检测的实用、成本效益平台，特别是在全球资源受限的环境中。

参考文献

[1] Y. Habchi, Y. Himeur, H. Kheddar, A. Boukabou, S. Atalla, A. Chouchane, A. Ouamane, and W. Mansoor, "AI in thyroid cancer diagnosis: Techniques, trends, and future directions," *Systems*, vol. 11, no. 10, p. 519, 2023.

[2] H. Sung, J. Ferlay, R. L. Siegel, M. Laversanne, I. Soerjomataram, A. Jemal, and F. Bray, "Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries," *CA: A Cancer Journal for Clinicians*, vol. 71, no. 3, pp. 209–249, 2021.

[3] A. Bir-Jmel, S. M. Douiri, S. E. Bernoussi, A. Maafiri, Y. Himeur, S. Atalla, W. Mansoor, and H. Al-Ahmad, "Gflasso-lr: logistic regression with generalized fused lasso for gene selection in high-dimensional cancer classification," *Computers*, vol. 13, no. 4, p. 93, 2024.

[4] A. Hamza, B. Lekouaghet, and Y. Himeur, "Hybrid whale-mud-ring optimization for precise color skin cancer image segmentation," in *2023 6th International Conference on Signal Processing and Information Security (ICSPIS)*. IEEE, 2023, pp. 87–92.

[5] Y. Habchi, H. Kheddar, Y. Himeur, A. Belouchrani, E. Serpedin, F. Khelifi, and M. E. Chowdhury, "Advanced deep learning and large language models: Comprehensive insights for cancer detection," *Image and Vision Computing*, vol. 157, p. 105495, 2025.

[6] E. B. Mendelson, "Practical ultrasound evaluation of breast lesions," *Radiologic Clinics of North America*, vol. 52, no. 6, pp. 1205–1220, 2014.

[7] E. P. Le, Y. Wang, Y. Huang, S. Hickman, and F. J. Gilbert, "Artificial intelligence in breast imaging," *Clinical Radiology*, vol. 74, no. 5, pp. 357–366, 2019.

[8] M. Ghaffari, A. Sowmya, and A. Oliver, "Impact of variability in ultrasound imaging on breast cancer diagnosis: A survey," *Ultrasound in Medicine & Biology*, vol. 46, no. 4, pp. 876–888, 2020.

[9] A. Bechar, Y. Elmir, R. Medjoudj, Y. Himeur, and A. Amira, "Harnessing transformers: A leap forward in lung cancer image detection," in *2023 6th International Conference on Signal Processing and Information Security (ICSPIS)*. IEEE, 2023, pp. 218–223.

[10] A. Bechar, R. Medjoudj, Y. Elmir, Y. Himeur, and A. Amira, "Federated and transfer learning for cancer detection based on image analysis," *Neural Computing and Applications*, vol. 37, no. 4, pp. 2239–2284, 2025.

[11] A. Bechar, Y. Elmir, Y. Himeur, R. Medjoudj, and A. Amira, "Enhancing cancer detection with fine-tuned large language models: A comparative study on low-rank adaptation," in *2024 IEEE/ACM International Conference on Big Data Computing, Applications and Technologies (BDCAT)*. IEEE, 2024, pp. 360–365.

[12] L. Zhang, "Deep learning for breast cancer detection in ultrasound images: A comprehensive review," *Journal of Imaging Research*, vol. 23, no. 4, pp. 300–310, 2021.

[13] Y. Habchi, H. Kheddar, and Y. Himeur, "Ultrasound images classification of thyroid cancer using deep transfer learning," in *2024 International Conference on Telecommunications and Intelligent Systems (ICTIS)*. IEEE, 2024, pp. 1–6.

[14] M. Liu, "Hybrid models for breast cancer detection: Combining CNNs and traditional ML approaches," *Journal of Medical AI*, vol. 19, no. 3, pp. 110–120, 2022.

[15] N. Patel, "AI-based feature extraction using transfer learning for breast cancer detection," *International Journal of Medical AI*, vol. 14, pp. 123–132, 2021.

[16] S. Kim et al., "Attention-based convolutional neural networks for breast cancer detection in ultrasound images," *Medical Image Analysis*, vol. 86, p. 102803, 2023.

[17] D. Wang, "Recent advances in ML algorithms for breast cancer detection," *Journal of Cancer Research*, vol. 25, pp. 300–315, 2023.

[18] H. Sun, "Comparative analysis of deep learning and traditional ML methods for breast cancer detection," *Journal of Healthcare AI*, vol. 20, no. 2, pp. 50–60, 2022.

[19] Y. Xiang et al., "Multicenter evaluation of deep learning for breast ultrasound diagnosis," *Radiology: Artificial Intelligence*, vol. 5, no. 2, p. e220214, 2023.

[20] H. Yan et al., "Interpretable deep learning model for breast ultrasound diagnosis in clinical practice," *Nature Medicine*, vol. 30, no. 2, pp. 210–218, 2024.

[21] J. Liu et al., "Deep radiomics of ultrasound images for breast lesion classification," *IEEE Transactions on Medical Imaging*, vol. 43, no. 1, pp. 101–110, 2024.

[22] Y. Habchi, H. Kheddar, Y. Himeur, M. C. Ghanem, A. Boukabou, S. Atalla, W. Mansoor, and H. Al-Ahmad, "Deep transfer learning for kidney cancer diagnosis," arXiv preprint arXiv:2408.04318, 2024.

[23] A. Bechar, Y. Elmir, R. Medjoudj, Y. Himeur, and A. Amira, "Transfer learning for cancer detection based on images analysis," *Procedia Computer Science*, vol. 239, pp. 1903–1910, 2024.

[24] W. Al-Dhabyani, M. Gomaa, H. Khaled, and A. Fahmy, "Dataset of breast ultrasound images," *Data in Brief*, vol. 28, p. 104863, 2020.

[25] W. Gómez-Flores, M. J. Gregorio-Calas, and W. C. A. Pereira, "BUS-BRA: A breast ultrasound dataset for assessing computer-aided diagnosis systems," *Medical Physics*, vol. 51, no. 4, pp. 3110–3123, 2024.

[26] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*. PMLR, 2019, pp. 6105–6114, pMLR Vol. 97.

[27] K. Jabeen, M. A. Khan, M. Alhaisoni, T. Saba, and A. Rehman, "Breast cancer classification from ultrasound images using probability-based optimal deep learning feature fusion," *Sensors*, vol. 22, no. 3, p. 807, 2022.

[28] Q. Jin, Y. Wang, X. Yang, and F. He, "CAM-based explainable deep learning models for medical image classification: A review," *IEEE Reviews in Biomedical Engineering*, vol. 16, pp. 62–75, 2023.

[29] Y. Oh, J. Park, and Y. Park, "Object detection in breast ultrasound using YOLOv5 and clinically interpretable evaluation," *Computers in Biology and Medicine*, vol. 136, p. 104649, 2021.

[30] N. Rieke et al., "The future of digital health with federated learning," *NPJ Digital Medicine*, vol. 3, no. 1, pp. 1–7, 2020.