華中科技大學

本科生毕业设计

基于深度学习的乳腺癌超声图像自动诊断系统设计与实现

院　　系　计算机科学与技术

专业班级　CS2202

姓　　名　雷传栋

学　　号　U202211999

指导教师　陆枫

2026 年 5 月

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名：　　2026 年 5 月

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于 1、保　密 □，在　　年解密后适用本授权书

2、不保密 ☑。

（请在以上相应方框内打“✓”）

作者签名：　　2026 年 5 月

导师签名：　　2026 年 5 月

摘 要

乳腺癌已成为全球女性发病率最高的恶性肿瘤，早期准确诊断对提高患者生存率具有决定性意义。乳腺超声检查因其无创无辐射、实时成像、适合致密型乳腺等优势，已被广泛用作一线筛查手段，但传统的人工判读方式高度依赖医生经验，存在主观性强、一致性差、效率受限等问题。近年来，深度学习技术在医学影像分析领域取得了突破性进展，为开发自动化的乳腺癌超声图像计算机辅助诊断（Computer-Aided Diagnosis, CAD）系统提供了新的技术路径。

本课题针对公开的 BUSI（Breast Ultrasound Images）数据集——包含 780 张良性、恶性、正常三类的乳腺超声图像——设计并实现了一套基于深度学习的自动诊断系统。研究采用五阶段递进式实验方法，系统地评估了不同技术方案对分类性能的影响。在基线实验中，基于 ResNet18 的迁移学习模型在无数据增强条件下达到 83.76% 的测试准确率；引入传统在线数据增强后提升至 86.32%；利用 DAGAN 生成对抗网络合成数据扩充训练集后进一步改善至 87.18%；采用混合增强策略结合 Focal Loss 损失函数使准确率达到 88.89%，其中正常组织识别率实现从 70% 到 95% 的质的飞跃；最终方案以 EfficientNet-B0 为骨干网络，综合运用 DAGAN 合成数据增强、标签平滑正则化、WeightedRandomSampler 均衡采样、300 × 300 高分辨率输入及轻量级增强等优化策略，在 117 张独立测试集上取得 94.87% 的整体准确率和 99.63% 的 AUC 值，各类别准确率分别为良性 96.97%、恶性 93.55%、正常 90.00%。此外，通过 Grad-CAM 梯度加权类激活映射技术生成了热力图可视化结果，验证了模型的决策依据与医学先验知识一致，确实聚焦于病灶区域进行判断。

实验结果表明，将传统数据增强与 GAN 合成数据相结合的混合增强策略能够互补性地改善不同类别的学习效果，配合适当的模型架构选型和训练技巧优化，能够在小规模医学图像数据集上训练出兼具高准确性和良好可解释性的深度学习分类模型，为乳腺癌超声图像智能诊断提供了一种可行的技术方案。

关键词： 乳腺癌超声图像；深度学习；卷积神经网络；数据增强；生成对抗网络；计算机辅助诊断

Abstract

Breast cancer has become the most prevalent malignant tumor among women globally, and early and accurate diagnosis is of decisive significance for improving patient survival rates. Breast ultrasound examination has been widely adopted as a first-line screening modality due to its advantages of being non-invasive, radiation-free, real-time imaging capability, and suitability for dense breast tissue. However, conventional manual interpretation relies heavily on radiologist expertise and suffers from limitations including subjectivity, poor consistency, and limited efficiency. In recent years, deep learning technology has made breakthrough progress in medical image analysis, providing a new technical pathway for developing automated breast ultrasound Computer-Aided Diagnosis (CAD) systems.

This thesis designs and implements a deep learning-based automated diagnostic system using the publicly available BUSI (Breast Ultrasound Images) dataset, which comprises 780 ultrasound images across three categories: benign, malignant, and normal. A five-stage progressive experimental methodology was employed to systematically evaluate the effects of different technical approaches on classification performance. In the baseline experiment, a ResNet18-based transfer learning model achieved 83.76% test accuracy without data augmentation; introducing traditional online data augmentation improved this to 86.32%; utilizing DAGAN (Deep convolutional Adversarial Generational Network) for synthetic data expansion further enhanced the result to 87.18%; adopting a hybrid augmentation strategy combined with Focal Loss yielded 88.89% accuracy, with normal tissue recognition achieving a qualitative leap from 70% to 95%. The final approach employed EfficientNet-B0 as the backbone network, comprehensively integrating DAGAN synthetic data augmentation, label smoothing regularization, WeightedRandomSampler balanced sampling, 300×300 high-resolution input, and lightweight augmentation strategies. On an independent test set of 117 images, this approach achieved an overall accuracy of 94.87% and an AUC of 99.63%, with class-wise accuracies of 96.97% for benign, 93.55% for

malignant, and 90.00% for normal cases. Additionally, Grad-CAM (Gradient-weighted Class Activation Mapping) heatmap visualizations were generated to verify that the model's decision-making aligns with medical prior knowledge by focusing on lesion regions during classification.

Experimental results demonstrate that combining traditional data augmentation with GAN-based synthetic data augmentation can complementarily improve the learning outcomes across different classes. When paired with appropriate backbone architecture selection and training technique optimization, it is feasible to train a deep learning classification model that achieves both high accuracy and strong interpretability on small-scale medical image datasets, providing a viable technical solution for intelligent breast ultrasound image diagnosis.

Keywords: Breast Ultrasound Image, Deep Learning, Convolutional Neural Network, Data Augmentation, Generative Adversarial Network, Computer-Aided Diagnosis

目 录

摘 要 ..... **I**

Abstract ..... **II**

1 绪 论 **1**

1.1 课题背景、目的与意义 1

1.2 国内外研究现状 4

1.3 论文的主要内容与结构 7

2 相关技术基础 **9**

2.1 卷积神经网络 9

2.2 U-Net 图像分割网络 11

2.3 DAGAN 生成对抗网络 12

2.4 Grad-CAM 可解释性方法 13

2.5 迁移学习策略 14

2.6 数据增强策略 15

2.7 本章小结 15

3 基于深度学习的乳腺癌超声图像诊断系统设计与实现 **17**

3.1 系统总体架构 17

3.2 数据处理流程 18

3.3 DAGAN 合成数据增强 20

3.4 分类模型设计 21

3.5 Grad-CAM 可解释性模块 23

3.6 测试时增强（TTA） 24

3.7 本章小结 25

4 实验与结果分析 **26**

4.1 实验环境与评估指标 26

4.2 实验方案设计 27

4.3 第一阶段：无数据增强基线实验 28

4.4 第二阶段：传统数据增强实验 29
4.5 第三阶段：DAGAN 合成数据增强实验 31
4.6 第四阶段：混合增强与损失函数优化实验 32
4.7 第五阶段：论文级优化实验 34
4.8 五阶段对比分析 36
4.9 Grad-CAM 可解释性可视化分析 36
4.10 本章小结 37
5 总结与展望 38
5.1 主要工作总结 38
5.2 主要创新点 39
5.3 不足与局限 40
5.4 未来工作展望 40
致谢 42
参考文献 43

1 绪 论

本章首先介绍乳腺癌超声图像自动诊断课题的研究背景与临床意义，分析当前乳腺超声诊断面临的挑战和深度学习技术带来的机遇；然后对国内外相关研究现状进行系统综述，涵盖深度学习在医学影像领域的应用进展、乳腺超声图像分类与分割方法以及模型可解释性技术；最后阐述本课题的主要研究内容、论文组织结构。

1.1 课题背景、目的与意义

1.1.1 研究背景

乳腺癌是全球女性最常见的恶性肿瘤之一，严重威胁女性生命健康。根据世界卫生组织（WHO）国际癌症研究机构（IARC）发布的《全球癌症统计报告》，2022 年全球新增乳腺癌病例约 230 万例，占所有女性癌症病例的 24.5%，已超越肺癌成为全球第一大癌症[1]。在中国，乳腺癌发病率同样呈快速上升趋势，国家癌症中心发布的数据显示每年新发病例约 42 万例，发病率以每年 3%–4% 的速度递增，且呈现明显的年轻化趋势，发病年龄中位数约为 48–50 岁，比西方国家提前约 10 年[2]。

乳腺癌的早期发现和准确诊断对于提高患者生存率具有决定性意义。临床研究表明，I 期乳腺癌的 5 年生存率可达 95% 以上，而一旦进展至 IV 期，5 年生存率骤降至 27% 左右[3]。因此，建立高效可靠的乳腺癌筛查和早期诊断体系具有重要的临床价值和公共卫生意义。

目前，乳腺癌的影像学检查手段主要包括乳腺 X 线摄影（钼靶）、超声检查、磁共振成像（MRI）等。其中，乳腺超声检查作为一线筛查手段，具有以下显著优势：（1）无创无辐射，不使用电离辐射，可反复检查，特别适合孕期和哺乳期女性；（2）实时成像，可动态观察病灶特征并评估血流情况；（3）适合致密型乳腺，对于亚洲女性常见的致密型乳腺组织，超声检查的敏感性优于钼靶；（4）成本低廉，设备和检查费用远低于 MRI，适合大规模筛查应用；（5）便携性好，便于基层医疗机构和移动医疗车配置[4]。

然而，传统的超声图像判读高度依赖放射科医生的经验和技能水平，存在以下突出问题：主观性强，不同医生对同一图像的判读结果可能存在显著差异；一致性差，同一医生在不同时间点的判读结果也可能不一致；效率受限，一名医生每天需要判读大量图像，长时间工作容易产生疲劳导致误判；资源分布不均，基层医疗机构往往缺乏经验丰富的影像科医生，诊断水平参差不齐。

随着深度学习技术的快速发展，以卷积神经网络（Convolutional Neural Network, CNN）为代表的人工智能方法为解决上述问题提供了新的技术路径。计算机辅助诊断（Computer-Aided Diagnosis, CAD）系统能够从大量医学图像中自动学习层次化特征表示，实现端到端的智能诊断，具有客观性强、一致性好、效率高等突出优点。近年来，深度学习在医学影像分析领域取得了突破性进展，在某些特定任务上的诊断性能已达到甚至超过人类专家的水平[5]。因此，开发基于深度学习的乳腺癌超声图像自动诊断系统具有重要的理论价值和应用前景。

1.1.2 面临的问题与挑战

尽管深度学习在医学影像分析领域展现出巨大潜力，但将深度学习技术应用于乳腺癌超声图像诊断仍面临以下关键挑战：

（1）**数据规模有限**。与自然图像数据集（如 ImageNet 包含 1400 万张标注图像）相比，医学影像数据集的规模通常较小。本课题采用的 BUSI 数据集仅包含 780 张超声图像，直接训练深度神经网络极易产生过拟合现象，严重制约模型的泛化能力。

（2）**类别分布不平衡**。BUSI 数据集中良性肿瘤样本 437 张（占比 56.0%），恶性肿瘤样本 210 张（占比 26.9%），正常组织样本 133 张（占比 17.1%），存在显著的类别不平衡问题。少数类样本（尤其是正常组织和恶性样本）的识别准确率往往较低，而这恰恰是临床诊断中最需要关注的关键类别——漏诊恶性病变或误诊正常组织的后果最为严重。

（3）**模型可解释性不足**。深度学习模型通常被视为”黑箱”，其内部决策逻辑难以被人类理解。在医疗诊断等高风险应用场景中，缺乏可解释性的 AI 系统难以获得临床医生的信任和认可，限制了其实际部署和应用。

（4）**超声图像的特殊性**。乳腺超声图像与自然图像存在本质差异：图像分辨

率不统一（500 × 500 至 1000 × 1000 像素不等）；图像质量受设备类型、操作手法、患者个体差异等因素影响较大；病灶区域通常只占整幅图像的很小比例；存在较多噪声和伪影干扰。这些特点使得直接套用针对自然图像设计的深度学习方法难以取得理想效果。

1.1.3 课题目的

针对上述挑战，本课题旨在设计并实现一个基于深度学习的乳腺癌超声图像自动诊断系统，主要目标包括：

（1）**实现高精度的图像分类**：构建基于迁移学习的卷积神经网络分类模型，对乳腺超声图像进行良性、恶性、正常三分类，测试集准确率达到 93% 以上，AUC 值达到 0.95 以上，为临床诊断提供可靠的定量参考依据；

（2）**探索有效的数据增强策略**：系统研究和对比传统数据增强与基于生成对抗网络（Generative Adversarial Network, GAN）的数据增强方法在小样本医学图像分类任务中的效果，缓解数据稀缺和类别不平衡问题；

（3）**提供可解释的诊断可视化**：通过梯度加权类激活映射（Grad-CAM, Gradient-weighted Class Activation Mapping）技术生成热力图，直观展示模型做出诊断决策时所关注的图像区域，增强系统的可信度和可解释性，促进人机协作诊疗模式的发展；

（4）**形成完整的原型系统**：将上述功能模块集成为一个具有友好用户界面的 Web 应用系统，支持图像上传、自动诊断、热力图可视化等功能，验证方法的工程可行性。

1.1.4 课题意义

从理论层面来看，本课题的研究意义体现在以下几个方面：首先，探索了如何将深度学习有效应用于小样本医学图像分析领域，通过迁移学习、数据增强等技术组合策略，为类似规模的医学影像数据分析提供方法论参考；其次，研究了传统数据增强与生成式增强方法的协同机制及其对分类性能的影响规律，丰富了医学图像数据增强技术的实验证据；再次，通过可解释性技术揭示了深度模型的诊断决策依据，推动了可信人工智能（Trustworthy AI）在医疗领域的应

用研究。

从实践层面来看，本课题开发的 CAD 系统可以作为放射科医生的”第二意见”辅助工具，帮助发现容易遗漏的可疑病灶，减少误诊和漏诊的发生概率，提升诊断的一致性和可靠性。特别是对于基层医疗机构而言，该系统能够提供接近专家水平的诊断参考能力，有助于缓解优质医疗资源分布不均的问题，促进医疗服务公平。

1.2 国内外研究现状

1.2.1 深度学习在医学影像分析中的应用进展

深度学习技术在医学影像分析领域的应用始于 2012 年 AlexNet 在 ImageNet 竞赛中的突破性表现[6]。此后，VGGNet[7]、GoogLeNet[8]、ResNet[9] 等经典卷积神经网络架构相继提出，不断刷新图像识别的性能基准。其中，ResNet 通过引入残差连接（Skip Connection）有效解决了深层网络的梯度消失问题，使得网络层数可以达到 152 层甚至更深，在 ImageNet 数据集上首次实现了 Top-5 错误率低于人类水平（3.57% vs 约 5%）的里程碑成就。

在医学影像领域，深度学习已广泛应用于 X 光片、CT、MRI、超声、病理切片等多种模态的图像分析任务中，取得了一系列重要突破。2016 年，Google 团队利用深度卷积神经网络进行糖尿病视网膜病变筛查，在包含 12.8 万张眼底照片的大规模数据集上，模型的敏感性和特异性分别达到 97.5% 和 93.4%，达到了资深眼科专家级的诊断水平[10]。2017 年，斯坦福大学 Esteva 等人开发的皮肤癌诊断深度学习系统，在包含 12.9 万张皮肤病变图像的数据集上，其诊断准确率与 21 名认证皮肤科医生相当，在某些情况下甚至超过了医生的平均水平[5]。2019 年，《Nature Medicine》发表的一项研究显示，Google AI 团队开发的肺癌低剂量 CT 筛查系统在 CT 图像分析中，相比放射科医生假阳性率降低了 11%，假阴性率降低了 5%[11]。这些研究成果充分证明了深度学习在医学影像诊断领域的巨大潜力和广阔应用前景。

1.2.2 乳腺超声图像分类方法研究

早期的乳腺超声图像分类主要依赖手工设计特征的机器学习方法，如灰度共生矩阵纹理特征、形状边缘形态特征等，结合支持向量机（SVM）或随机森林等分类器进行分类。这类方法的性能高度依赖于特征工程的质量，且泛化能力有限。

近年来，基于深度学习的端到端分类方法已成为主流研究方向，主要可分为以下几个技术路线：

（1）**迁移学习方法**是当前最为主流的技术路线。由于医学图像数据集规模通常仅有数百至数千张，远不足以从头训练深层卷积神经网络，研究者普遍采用在 ImageNet 等大规模自然图像数据集上预训练的模型作为特征提取器进行微调。Byra 等人[12] 使用 ResNet50 在包含 882 张乳腺超声图像的数据集上，通过迁移学习实现了 89.2% 的分类准确率。Han 等人[13] 采用 DenseNet121 在 BUSI 数据集上进行实验，达到了 88.4% 的准确率和 0.92 的 AUC 值。Al-Dhabyani 等人[4] 在其开创性工作中系统比较了多种 CNN 架构（包括 ResNet18、MobileNet、DenseNet121 等）在 BUSI 数据集上的分类性能，为后续研究提供了重要的基线参考。

（2）**轻量级网络**方向关注模型的计算效率和部署便利性。考虑到移动医疗设备和嵌入式系统的算力限制，MobileNet、ShuffleNet、EfficientNet 等轻量级网络被引入乳腺超声分类任务。这些网络架构通过深度可分离卷积（Depthwise Separable Convolution）、通道混洗（Channel Shuffle）等技术，在保持较高精度的同时大幅降低参数量和计算复杂度。Zhang 等人[14] 使用改进的 MobileNetV2 在乳腺超声分类任务上达到了 86.7% 的准确率，模型体积仅为 14MB。Tan 和 Le[15] 提出的 EfficientNet 系列通过对网络深度、宽度和分辨率的联合优化，在多个基准测试中以更少的参数量超越了此前的先进模型，为本课题最终方案的选择提供了重要参考。

（3）**Transformer 架构**近年开始向医学影像领域渗透。Dosovitskiy 等人[16] 提出的 Vision Transformer（ViT）将自然语言处理中的自注意力机制引入计算机视觉，展现出对长距离依赖关系的强大建模能力。Wang 等人提出的 TransMed 模

型在多模态医学影像分析中取得了良好效果。然而，Transformer 架构通常需要更大的数据集和更多的计算资源来充分训练，在小规模医学图像数据集上的应用仍面临一定挑战。

（4）**集成学习方法**通过组合多个独立模型的预测结果以进一步提升分类鲁棒性和准确性。常见的集成策略包括投票法、加权平均法和堆叠泛化法（Stacking）。Qi 等人[17] 集成 ResNet、DenseNet 和 Inception 三个模型，在乳腺超声分类任务上将准确率提升至 91.3%。但集成方法也带来了更高的计算开销和系统复杂度。

1.2.3 医学图像数据增强技术

数据增强是缓解小样本医学图像过拟合问题的关键技术手段之一。现有的数据增强方法大致可分为两类：

（1）**传统数据增强**方法通过对原始图像施加几何变换或颜色变换来人工扩充训练集，具体操作包括随机水平翻转、随机旋转、随机裁剪缩放、亮度/对比度调整、弹性形变（Elastic Deformation）等。这类方法实现简单、计算开销小，已被广泛采用为标准的数据预处理流程。Shorten 和 Khoshgoftaar[18] 对各类数据增强技术进行了全面的综述和分析。然而，传统增强方法本质上只是对已有数据的变换重组，无法从根本上增加数据的多样性，对于极度不平衡的小样本数据集效果有限。

（2）**生成式数据增强**方法试图从数据分布层面解决数据稀缺问题。Goodfellow 等人[19] 提出的生成对抗网络（GAN）由生成器和判别器两部分组成，通过对抗训练的方式学习真实数据的分布，进而生成逼真的合成样本。在医学图像领域，GAN 被广泛用于数据扩充、图像重建、跨模态转换等任务。Mao 等人[20] 提出的最小二乘 GAN（LSGAN）改善了训练稳定性。针对医学图像数据增强的具体需求，Al-Dhabyani 等人[4] 提出了面向乳腺超声图像的 DAGAN（Deep convolutional Adversarial Generative Network）方法，能够根据指定的类别标签生成高质量的合成超声图像，在 BUSI 数据集上取得了显著的性能提升。这是本课题核心实验方案的重要理论基础。

1.2.4 深度学习模型可解释性技术

深度学习模型的”黑箱”特性是其在医疗等高风险领域落地应用的主要障碍之一。可解释性 AI（Explainable AI, XAI）研究致力于揭示模型的内部决策逻辑，主要技术路线包括：

（1）**CAM 系列方法**是最为直观和常用的可视化解释技术。Zhou 等人[21] 首先提出了类激活映射（Class Activation Mapping, CAM），通过全局平均池化层权重与卷积特征图的加权和来定位图像中对分类贡献最大的区域。Selvaraju 等人[22] 进一步提出了 Grad-CAM 方法，利用目标类别相对于最后一个卷积层特征图的梯度信息生成加权热力图，无需修改网络结构即可适用于任意 CNN 架构，适用性更为广泛。后续的 Grad-CAM++[23] 和 Score-CAM[24] 等方法进一步提升了定位精度和视觉效果。

（2）**基于扰动的方法**通过局部扰动输入图像来评估各区域对预测结果的重要性。Ribeiro 等人[25] 提出的 LIME（Local Interpretable Model-agnostic Explanations）在输入空间附近采样并通过拟合局部线性模型来近似解释模型行为。Lundberg 和 Lee[26] 提出的 SHAP 方法基于博弈论中的 Shapley 值为每个输入特征分配重要性分数，具有坚实的数学理论基础。

在本课题中，选用 Grad-CAM 作为主要的可解释性工具，原因在于其计算效率高、无需修改模型结构、生成的热力图直观易理解，非常适合集成到实时的 CAD 系统中。

1.3 论文的主要内容与结构

1.3.1 主要内容

本课题围绕基于深度学习的乳腺癌超声图像自动诊断这一核心问题，开展的主要研究内容包括以下四个方面：

（1）**数据集构建与预处理**：基于公开的 BUSI 乳腺超声图像数据集，完成数据清洗、尺寸归一化、标准化等预处理操作，采用分层抽样策略划分训练集、验证集和测试集，并实现基于 DAGAN 的合成数据生成以扩充和平衡训练集。

（2）**分类模型设计与优化**：以预训练的卷积神经网络（ResNet18 和 EfficientNet-B0）为基础，通过迁移学习策略适配乳腺超声图像三分类任务。系统性地研究传统数据增强、DAGAN 合成数据增强、混合增强策略以及均衡采样、标签平滑等训练技巧对模型性能的影响，通过五阶段递进式实验确定最优配置方案。

（3）**可解释性分析与可视化**：实现 Grad-CAM 热力图生成算法，对分类模型的决策过程进行可视化分析，验证模型是否真正聚焦于病灶区域进行判断。

（4）**系统集成与验证**：开发基于 Web 的 CAD 原型系统，整合图像上传、分类预测、热力图展示等功能，验证整体方案的工程可行性和实用性。

1.3.2 论文结构

本文共分为五章，各章内容安排如下：

第一章为绪论。介绍乳腺癌超声诊断课题的研究背景、临床意义及面临的关键挑战，综述深度学习在医学影像分析领域的应用现状、乳腺超声图像分类方法和数据增强技术的研究进展，阐明本课题的研究目的与意义，概述论文的主要内容和组织结构。

第二章为相关技术基础。介绍本课题所依赖的核心技术原理，包括卷积神经网络的基本原理与代表性架构（ResNet 和 EfficientNet）、U-Net 分割网络、生成对抗网络（DAGAN）用于医学图像合成的原理、Grad-CAM 可解释性方法，以及迁移学习和数据增强的基本概念。

第三章为系统设计与实现方法。详细描述乳腺癌超声图像自动诊断系统的总体设计方案，包括数据处理流水线、分类模型架构、DAGAN 合成数据增强流程、Grad-CAM 可解释性模块的设计与实现细节。

第四章为实验与结果分析。介绍实验环境配置和数据集划分方案，通过五阶段递进式实验系统地分析和对比不同技术方案的性能表现，展示最优模型在测试集上的详细评估结果和可视化分析。

第五章为总结与展望。总结本课题的主要研究工作和创新点，讨论存在的不足，并对未来可能的研究方向进行展望。

2 相关技术基础

本章介绍本课题所依赖的核心技术基础，为后续系统设计与实验分析提供必要的理论支撑。首先阐述卷积神经网络的基本原理和本课题选用的两种骨干网络架构——ResNet 与 EfficientNet；其次介绍用于医学图像分割的 U-Net 网络结构和 DAGAN 生成对抗网络的合成数据原理；然后说明 Grad-CAM 可解释性方法的技术细节；最后讨论迁移学习和数据增强策略在本课题中的具体应用方式。

2.1 卷积神经网络

2.1.1 基本原理

卷积神经网络（Convolutional Neural Network, CNN）是一类专门设计用于处理具有网格拓扑结构数据（如图像、时间序列）的深度前馈神经网络。CNN 的核心思想是通过局部感受野（Local Receptive Field）、权重共享（Weight Sharing）和池化操作（Pooling）这三个关键机制，有效提取图像中的层次化特征表示。

一个典型的卷积神经网络由多种类型的层堆叠而成：（1）**卷积层**通过可学习的卷积核在输入特征图上进行滑动窗口计算，提取局部空间特征，每个卷积核对应一种特定的特征检测器（如边缘、纹理、形状等）；（2）**激活函数层**引入非线性变换，使得网络能够学习复杂的非线性映射关系，常用的激活函数包括 ReLU（Rectified Linear Unit）、Leaky ReLU、GELU 等；（3）**池化层**对特征图进行下采样以降低空间分辨率，增强特征的平移不变性并减少计算量；（4）**全连接层**位于网络末端，将学习到的高层语义特征映射到输出类别空间；（5）**归一化层**如批归一化（Batch Normalization），加速训练收敛过程并提高模型稳定性。

CNN 的特征提取具有明显的层次性：浅层卷积核通常学习到低级视觉特征（边缘、角点、颜色斑块等），中层卷积核组合低级特征形成中级模式（纹理、局部形状等），深层卷积核则捕获高级语义概念（物体部件、完整对象等）。这种层次化的特征学习机制使得 CNN 在图像分类任务中表现出色。

2.1.2 残差网络 ResNet

随着网络深度的增加，传统的卷积神经网络面临着梯度消失/爆炸和退化（Degradation）问题：更深的网络往往不仅没有带来性能提升，反而导致训练误差和测试误差同时上升。He 等人[9] 于 2015 年提出的残差网络（Residual Network, ResNet）通过引入残差学习（Residual Learning）框架有效解决了这一难题。

残差块（Residual Block）的核心思想是让网络学习输入与目标输出之间的残差映射 $F(x) = H(x) - x$，而非直接学习映射 $H(x)$。对于一个残差块，其输出可以表示为：

$$y = F(x, \{W_i\}) + x \tag{2-1}$$

其中 x 为残差块的输入，$F(x, \{W_i\})$ 表示需要学习的残差映射（通常由两层或更多层卷积构成），y 为残差块的输出。当恒等映射是最优解时（即 $H(x) = x$），将 $F(x)$ 优化至 0 比直接学习恒等映射要容易得多。这一简单而优雅的设计使得训练数百甚至上千层的深度网络成为可能。

ResNet18 是 ResNet 家族中的轻量级版本，共包含 18 个可学习参数层（17 个卷积层 +1 个全连接层），参数量约为 1117 万。其结构包括：1 个初始卷积层（7×7 卷积核，步长为 2）、1 个最大池化层、8 个残差块（分为 4 个阶段，每阶段包含 2 个残差块）、1 个全局平均池化层和 1 个全连接分类层。4 个阶段的通道数依次为 64、128、256、512，每个阶段内部的空间分辨率减半而通道数翻倍。ResNet18 凭借其适中的模型规模和良好的性能表现，被广泛用作迁移学习的基线模型，也是本课题前期实验阶段的核心骨干网络。

2.1.3 EfficientNet

尽管 ResNet 系列取得了巨大成功，但其网络架构的设计主要依赖于人工经验和试错，缺乏系统性的缩放策略。Tan 和 Le[15] 于 2019 年提出的 EfficientNet 通过复合缩放（Compound Scaling）方法，系统性地研究了网络深度（Depth）、宽度（Width）和分辨率（Resolution）三个维度之间的最优平衡关系。

传统的人工网络缩放通常只调整其中一个维度（如只增加网络层数），这种方式效率低下且容易陷入次优配置。EfficientNet 提出使用一组固定的系数来联

合缩放三个维度：

$$\begin{cases} depth: & d = \alpha^{\phi} \\ width: & w = \beta^{\phi} \quad s.t.\ \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \\ resolution: & r = \gamma^{\phi} \end{cases} \tag{2-2}$$

其中 ϕ 为用户指定的缩放系数，α、β、γ 为通过网格搜索确定的最优常数。约束条件 $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ 确保在网络规模增加约 2^{ϕ} 倍时，总浮点运算量（FLOPs）也同步增加约 2^{ϕ} 倍，维持了各维度间的均衡增长。

EfficientNet-B0 是 EfficientNet 系列的基准模型，采用 MobileNet 风格的倒残差 inverted bottleneck 结构作为基本构建单元，结合了 squeeze-and-excitation 注意力机制来动态调整通道权重，参数量仅为约 400 万，显著小于 ResNet18 的同时在 ImageNet 上达到了更高的准确率（77.1% vs 69.3% Top-1）。这些特性使得 EfficientNet-B0 特别适合小样本医学图像分类任务，因此被选为本课题最终方案的骨干网络架构。

2.2 U-Net 图像分割网络

U-Net[27] 是由 Ronneberger 等人于 2015 年专门针对医学图像分割任务提出的全卷积神经网络架构。该网络在 ISBI 2015 细胞分割挑战赛中以显著优势夺冠，此后成为医学图像分割领域最广泛使用的基线架构之一。

U-Net 采用对称的编码器-解码器（Encoder-Decoder）结构，整体呈”U” 形，故得名：

（1）**编码器（下采样路径）**：由连续的下采样块组成，每个下采样块包含两个 3×3 卷积层（每个卷积后接 ReLU 激活函数和一个 2×2 最大池化层（步长为 2）。每经过一次池化操作，特征图的空间分辨率减半，通道数翻倍，逐步提取从低级到高级的多尺度语义特征。

（2）**解码器（上采样路径）**：由连续的上采样块组成，每个上采样块包含一个 2×2 转置卷积层（或双线性上采样 +3×3 卷积）进行上采样恢复空间分辨率，随后接两个 3×3 卷积层。每经过一次上采样操作，特征图的空间分辨率加倍，通道数减半。

（3）**跳跃连接（Skip Connections）**：这是 U-Net 最核心的设计创新。编码器中每一层的特征图通过拼接（Concatenation）操作直接传递到解码器中对应分辨率的层。跳跃连接的作用是将编码器的高分辨率位置信息（来自浅层特征）与解码器的高层语义信息（来自深层特征）进行融合，帮助解码器更精确地定位目标边界。

（4）**输出层**：在解码器的末端，使用 1×1 卷积将特征通道数映射到类别数，配合 Sigmoid 激活函数（二分类）或 Softmax 激活函数（多分类）输出每个像素的类别概率预测。

对于医学图像分割任务，常用的损失函数为 Dice Loss，定义为：

$$L_{Dice} = 1 - \frac{2|P \cap G| + \epsilon}{|P| + |G| + \epsilon} \tag{2-3}$$

其中 P 表示模型预测结果，G 表示真实标签掩码，ϵ 为平滑项（通常取 10^{-6}）以防止分母为零。Dice Loss 直接优化 Dice 相似系数（DSC），对于处理前景/背景严重不平衡的分割问题特别有效。

2.3 DAGAN 生成对抗网络

生成对抗网络（Generative Adversarial Network, GAN）[19] 是一种通过对抗过程训练生成模型的框架。GAN 包含两个相互博弈的神经网络：**生成器**（Generator, G）学习从随机噪声向量 z（或条件向量 c）到真实数据空间的映射，试图生成逼真的样本；**判别器**（Discriminator, D）则尝试区分真实样本和生成样本。两者通过最小极大博弈（Minimax Game）交替优化：

$$\min_G \max_D \mathbb{E}_{x \sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))] \tag{2-4}$$

当达到纳什均衡时，生成器产生的分布趋近于真实数据分布，判别器无法区分真假样本。

面向乳腺超声图像合成的 DAGAN（Deep convolutional Adversarial Generative Network）[4] 是一种条件 GAN 变体，其特点在于：（1）生成器和判别器均采用深度卷积架构（DCGAN 风格），使用转置卷积进行逐层上采样生成图像；（2）引入条件变量 c（即图像类别标签：良性/恶性/正常），使生成器能够根据指定类别定向生成对应类别的超声图像；（3）在判别器中采用标签嵌入（Label Embedding）

策略，将类别信息融入判别过程。

DAGAN 的训练流程如下：首先从真实 BUSI 数据集中按类别分别训练独立的 GAN 模型（即每个类别训练一个 DAGAN）；训练完成后，利用生成器批量合成各类别的超声图像；将合成图像按一定比例混入原始训练集中，扩充训练数据的数量和多样性，特别是增加少数类（恶性、正常）的样本量，缓解类别不平衡问题。

在本课题中，DAGAN 生成的合成数据被用于 Stage 3 及之后的实验阶段，原始训练集 546 张加上 2730 张合成图像后，总训练样本数扩展至 3276 张（约 6 倍增幅），为后续的分类性能提升提供了重要的数据支撑。

2.4 Grad-CAM 可解释性方法

梯度加权类激活映射（Gradient-weighted Class Activation Mapping, Grad-CAM）[22] 是 Selvaraju 等人于 2017 年提出的一种无需修改网络结构即可为任意 CNN 模型生成可视化解释的方法。该方法利用目标类别相对于最后一个卷积层输出特征图的梯度信息，定位出对预测结果贡献最大的图像区域。

Grad-CAM 的具体算法流程如下：

（1）**前向传播**：给定输入图像 x，通过网络前向传播获取最后一个卷积层的特征图 A^k（其中 k 表示第 k 个通道）以及目标类别 c 的原始得分 y^c。

（2）**梯度计算**：计算类别得分 y^c 相对于特征图 A^k 的梯度 $\frac{\partial y^c}{\partial A^k}$，该梯度编码了每个像素对类别 c 得分的重要性。

（3）**全局平均池化求权重**：对梯度特征图进行全局平均池化，得到每个通道的重要性权重 α_k^c：

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \tag{2-5}$$

其中 Z 为特征图的空间尺寸（高 × 宽），α_k^c 反映了第 k 个特征通道对目标类别 c 的相对重要性。

（4）**加权融合与 ReLU 激活**：将所有通道的特征图按照对应的权重 α_k^c 进行线性加权求和，并通过 ReLU 激活函数过滤负值：

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right) \tag{2-6}$$

ReLU 操作的含义是：只保留那些对目标类别得分有正向贡献的特征（即增加该类别得分的特征），忽略可能属于其他类别或其他图像区域的特征。

（5）**上采样与可视化**：将生成的热力图 $L^c_{Grad-CAM}$ 通过双线性插值上采样至原始输入图像的尺寸，应用颜色映射（如热力图配色方案 JET）后叠加到原图上显示。

Grad-CAM 的主要优点包括：适用性广，可用于任何基于 CNN 的架构而无需修改网络结构或重新训练；计算高效，仅需一次反向传播即可获得热力图；可视化直观，热力图的高亮区域清晰展示了模型做出判断所依据的图像区域，便于临床医生理解和验证 AI 的诊断逻辑。

2.5 迁移学习策略

迁移学习（Transfer Learning）是指将在源域（Source Domain）大规模数据集上学到的知识迁移应用到目标域（Target Domain）任务中的机器学习方法[28]。在计算机视觉领域，最常见的迁移学习范式是在 ImageNet（包含 1400 万张标注图像、1000 个类别）等大规模自然图像数据集上预训练的 CNN 模型为基础，通过微调（Fine-tuning）适配到特定的下游目标任务。

对于医学图像分类这类小样本场景，迁移学习之所以有效的根本原因在于：CNN 底层卷积核学习到的通用视觉特征（如边缘、纹理、形状等）在不同领域的图像之间具有一定的共享性和可迁移性。即使医学图像与自然图像存在显著的视觉差异，这些底层特征的迁移仍然能够提供良好的初始化，大幅减少目标任务所需的训练数据和训练时间，降低过拟合风险。

本课题采用的迁移学习策略包括：（1）加载 ImageNet 预训练的骨干网络权重作为初始化；（2）替换原始的全连接分类层，将其输出维度适配为目标任务的类别数（3 类）；（3）冻结部分早期卷积层的参数（可选），仅微调深层特征和分类层；或采用全量微调策略配合较小的学习率。

2.6 数据增强策略

2.6.1 传统数据增强

传统数据增强通过对原始训练图像施加一系列预定义的几何变换和颜色变换来人工扩充训练集。本课题采用的在线数据增强策略包括以下操作：

（1）**几何变换**：随机水平翻转（概率 50%），模拟病灶可能出现在乳腺左右两侧的情况；随机旋转（±10° 范围内），适应超声探头角度的微小差异；随机缩放（90%–110% 范围），模拟不同距离下的成像大小变化。

（2）**颜色抖动**：随机亮度调整（±20%）和随机对比度调整（±20%），模拟不同设备设置和患者个体差异造成的图像亮度和对比度变化。

需要特别强调的是，数据增强操作**仅在训练阶段**应用于训练集样本。验证集和测试集仅执行标准的预处理操作（尺寸归一化、张量化、标准化），不施加任何增强变换，以确保评估结果的客观性和可比性。

2.6.2 基于 GAN 的合成数据增强

与传统增强方法只能对已有数据进行变换重组不同，基于 GAN 的合成增强能够从数据分布层面生成全新的样本。DAGAN 针对 BUSI 数据集中每个类别独立训练生成模型，能够根据类别条件定向合成对应类别的乳腺超声图像。

本课题的具体做法是：（1）使用 Al-Dhabyani 等人提供的预训练 DAGAN 模型或自行在每个类别上训练 DAGAN；（2）为少数类（恶性和正常）生成更多合成样本以平衡类别分布；（3）将合成图像与原始图像合并构成扩展后的训练集，在后续训练迭代中统一参与模型优化。实验结果表明，合成数据的引入显著提升了模型在少数类上的识别准确率，尤其是良性肿瘤类别的准确率从 96.49% 提升至 98.25%。

2.7 本章小结

本章系统地介绍了本课题所涉及的核心技术基础。首先阐述了卷积神经网络的基本原理，详细分析了两种骨干网络架构——ResNet18 和 EfficientNet-B0 的

结构特点和设计动机；其次介绍了用于医学图像分割的 U-Net 网络的编码器-解码器架构和跳跃连接机制；然后阐述了 DAGAN 生成对抗网络的工作原理及其在医学图像合成中的应用方式；接着说明了 Grad-CAM 可解释性方法的完整算法流程；最后讨论了迁移学习和两类数据增强策略在本课题中的具体实现方式。以上技术基础为下一章的系统设计与实现奠定了理论基础。

3 基于深度学习的乳腺癌超声图像诊断系统设计与实现

本章详细描述基于深度学习的乳腺癌超声图像自动诊断系统的整体设计方案与具体实现。首先介绍系统的总体架构和各模块的功能划分；然后阐述数据处理流程，包括数据集介绍、预处理操作、数据集划分策略以及 DAGAN 合成数据的生成方法；接着详细说明分类模型的设计方案，包括骨干网络选择、迁移学习配置、损失函数设计和训练策略优化；最后介绍 Grad-CAM 可解释性模块和测试时增强（TTA）推理方法的实现细节。

3.1 系统总体架构

本课题设计的乳腺癌超声图像自动诊断系统采用模块化的软件架构，主要由四个核心功能模块组成：

（1）**数据预处理模块**：负责原始乳腺超声图像的加载、清洗、尺寸归一化、标准化等预处理操作，以及训练集/验证集/测试集的分层划分和数据增强变换。

（2）**分类模型模块**：系统的核心模块，基于预训练的卷积神经网络（EfficientNet-B0 或 ResNet18），通过迁移学习实现良性、恶性、正常三分类功能。

（3）**DAGAN 合成数据增强模块**：利用深度卷积生成对抗网络为训练集生成高质量合成样本，扩充训练数据量并缓解类别不平衡问题。

（4）**Grad-CAM 可解释性模块**：对分类模型的预测结果生成热力图可视化，展示模型做出决策时所关注的关键区域，提供可解释的诊断依据。

系统的整体处理流程如图3-1所示。输入的乳腺超声图像经过预处理后送入分类模型进行推理，输出三分类预测结果及各类别置信度；同时，Grad-CAM 模块对最后一个卷积层的特征图进行梯度加权计算，生成热力图并叠加于原图上进行可视化展示。

系统架构图（待插入）

图 3-1　乳腺癌超声图像自动诊断系统总体架构

3.2　数据处理流程

3.2.1　数据集介绍

本课题采用 BUSI（Breast Ultrasound Images Dataset）数据集[4] 作为实验数据来源。该数据集由埃及 Al-Azhar 大学的研究团队于 2020 年公开发布，是目前公开可用的最大规模乳腺超声图像数据集之一。

数据集的基本统计信息如表3-1所示。全部 780 张图像均由专业放射科医生进行标注和质量审核，每张图像对应一个分类标签（良性/恶性/正常）。对于包含肿瘤病灶的图像（良性和恶性类别），数据集还提供了对应的像素级分割掩码（PNG 格式），可用于分割任务训练和病灶区域可视化分析。

表 3-1　BUSI 数据集统计信息

类别	样本数量	占比	分割掩码
良性（Benign）	437	56.0%	有
恶性（Malignant）	210	26.9%	有
正常（Normal）	133	17.1%	无
合计	780	100%	–

数据集具有以下特点：（1）所有图像来源于真实的临床检查场景，具有较高的临床代表性；（2）图像分辨率不统一，范围从 500 × 500 到 1000 × 1000 像素不等；（3）数据采集使用了多种不同型号的超声设备，具有一定的设备多样性；（4）三类之间存在显著的类别不平衡问题，良性样本数约为恶性样本的 2 倍、正常

样本的 3.3 倍。

3.2.2 图像预处理

针对 BUSI 数据集的特点，设计如下标准化的图像预处理流水线：

（1）**尺寸归一化**：将所有图像统一缩放至目标分辨率。对于 ResNet18 骨干网络，目标尺寸为 224×224 像素；对于 EfficientNet-B0 骨干网络，目标尺寸为 300×300 像素（EfficientNet-B0 默认输入分辨率为 224，但实验表明提升至 300 可获得更好的性能）。采用双线性插值（Bilinear Interpolation）进行缩放以保持图像平滑性。

（2）**张量化**：将 PIL 格式的图像转换为 PyTorch 张量，并将像素值范围从 $[0, 255]$ 映射到 $[0.0, 1.0]$ 区间。

（3）**标准化**：使用 ImageNet 数据集的均值和标准差对张量进行标准化：

$$x'_c = \frac{x_c - \mu_c}{\sigma_c}, \quad c \in \{R, G, B\} \tag{3-1}$$

其中 $\mu = [0.485, 0.456, 0.406]$ 为 ImageNet RGB 三通道均值，$\sigma = [0.229, 0.224, 0.225]$ 为对应的标准差。使用 ImageNet 标准化参数的原因在于本课题采用的骨干网络均为 ImageNet 预训练模型，保持一致的分布假设有助于迁移学习的有效性。

上述三项预处理操作（Resize → ToTensor → Normalize）构成基础预处理管线，应用于**所有**数据集（包括训练集、验证集和测试集）的所有样本。

3.2.3 数据集划分策略

本课题采用分层抽样（Stratified Sampling）策略将完整数据集划分为训练集、验证集和测试集三个互不重叠的子集。分层抽样确保每个子集中各类别的比例与原始数据集中的类别分布保持一致，避免因随机抽样导致的类别比例偏移。

实验中采用了两种划分方案以进行对比验证：

方案一（70/15/15 划分）：训练集 546 张（70%）、验证集 117 张（15%）、测试集 117 张（15%）。该方案为论文的主要汇报方案，测试集规模较大（117 张），评估结果更为可靠稳健。

方案二（80/10/10 划分）：训练集 624 张（80%）、验证集 78 张（10%）、测试集 78 张（10%）。该方案用于交叉验证，测试集约 78 张。

两种方案均使用固定随机种子（seed=42）保证实验的可重复性，且经过严格的数据泄露检验——三个子集之间不存在任何交集，合成数据仅被注入训练集，验证集和测试集完全由原始真实图像组成。

3.3 DAGAN 合成数据增强

3.3.1 合成数据生成

DAGAN（Deep convolutional Adversarial Generative Network）是一种专门面向医学图像合成的条件生成对抗网络。在本课题中，利用 DAGAN 为 BUSI 数据集中的每个类别独立地生成合成超声图像样本，具体过程如下：

对于每个类别 $c \in \{benign, malignant, normal\}$，在属于该类别的原始图像上训练一个独立的 DAGAN 模型。生成器 G_c 学习从噪声向量 z 到类别 c 图像空间的映射，判别器 D_c 区分真实图像和合成图像。训练收敛后，使用生成器批量生成指定数量的合成图像。

本课题中各类别生成的合成样本数量设定原则是使扩充后的训练集在每个类别上达到近似均衡。具体而言，原始训练集 546 张图像的类别分布为 benign:306 张、malignant:147 张、normal:93 张。通过 DAGAN 分别为三个类别额外生成合成图像后，总训练样本扩展至 3276 张（含 2730 张合成图像），大幅缓解了类别不平衡问题。

3.3.2 合成数据的集成方式

合成图像被离线生成并存储至磁盘后，在训练阶段以以下方式与原始数据集成：

（1）构建两个独立的 ‘Dataset‘对象：原始数据集（包含 546 张真实图像）和合成数据集（包含 2730 张合成图像）；

（2）使用 PyTorch 的 ‘ConcatDataset‘将两者拼接为一个统一的组合数据集；

（3）在后续的训练迭代中，数据加载器从组合数据集中按批次采样，原始图像和合成图像共同参与梯度计算和参数更新；

（4）合成数据同样接受在线数据增强变换（翻转、旋转等），进一步增强多样性。

需要特别说明的是，合成数据**仅参与训练过程**，验证集和测试集完全由未参与任何增强操作的原始真实图像组成，以确保模型性能评估的客观性和公正性。

3.4 分类模型设计

3.4.1 骨干网络选择与适配

本课题在实验过程中先后采用了两种骨干网络架构：ResNet18 和 EfficientNet-B0。

ResNet18 作为前期实验（Stage 1–Stage 4）的骨干网络，其优势在于结构经典、资料丰富、社区成熟度高。具体的模型适配方式为：加载 PyTorch 官方提供的 ImageNet 预训练权重；移除原始的全连接分类层（fc 层，原输出维度 1000）；替换为新的全连接层，输出维度设为 3（对应良性、恶性和正常三个类别）；可选地冻结部分浅层卷积参数以防止在小数据集上的过拟合。

EfficientNet-B0 作为最终方案（Stage 5）的骨干网络，其优势在于以更少的参数量（约 400 万 vs ResNet18 约 1117 万）实现了更高的 ImageNet 准确率，且复合缩放策略使其在多种输入分辨率下均能保持良好的效率-精度平衡。模型适配方式与 ResNet18 类似：加载预训练权重，替换分类头为 3 维输出层。此外，在分类头前增加了 Dropout 层（丢弃率 0.5）作为正则化手段。

3.4.2 损失函数设计

分类任务的核心损失函数选用交叉熵损失（Cross-Entropy Loss）。对于一个样本 (x, y)，其中 x 为输入图像，$y \in \{0, 1, 2\}$ 为真实标签，交叉熵损失定义为：

$$L_{CE} = -\log \frac{\exp(f_y(x))}{\sum_{k=0}^{2} \exp(f_k(x))} = -f_y(x) + \log\left(\sum_{k=0}^{2} \exp(f_k(x))\right) \tag{3-2}$$

其中 $f_k(x)$ 为模型对第 k 类的原始输出得分（logits）。

为进一步提高模型的泛化能力和校准性，在 Stage 5 的最终方案中引入了标签平滑（Label Smoothing, LS）技术[29]。标签平滑通过对真实标签分布施加均匀噪声来正则化模型，使其不会对训练样本产生过度自信的预测。平滑后的标签分布 $\tilde{y}_k$ 定义为：

$$\tilde{y}_k = \begin{cases} 1-\alpha & \text{if } k = y \\ \alpha/(K-1) & \text{if } k \neq y \end{cases} \tag{3-3}$$

其中 $K = 3$ 为类别数，α 为平滑系数。本课题设置 $\alpha = 0.1$，即真实标签的置信度从 1.0 降至 0.9，剩余 0.1 的概率质量均匀分配给其余两个错误标签。结合标签平滑后的损失函数变为标准的交叉熵损失作用于平滑标签分布 $\tilde{y}$ 上。

3.4.3 均衡采样策略

针对 BUSI 数据集中严重的类别不平衡问题，除了通过 DAGAN 合成数据增加少数类样本量之外，本课题还采用了 WeightedRandomSampler（加权随机采样器）来实现均衡采样。

WeightedRandomSampler 的基本原理是为每个训练样本分配一个采样权重，权重与该样本所属类别的频率成反比。设类别 k 的样本数为 n_k，则属于类别 k 的每个样本的采样权重为：

$$w_k = \frac{N}{K \cdot n_k} \tag{3-4}$$

其中 N 为训练集总样本数，K 为类别数。这样，少数类样本被采样的概率更高，多数类样本被采样的概率更低，使得每个 mini-batch 中的类别分布在期望上趋于均衡。

在实际实现中，WeightedRandomSampler 应用于 ConcatDataset（原始 + 合成数据）之上。由于合成数据的加入已经显著改善了类别分布，均衡采样的作用更多是在微调层面进一步确保训练过程中模型对各类别的关注度保持一致。

3.4.4 优化器与学习率调度

本课题统一采用 Adam 优化器[30] 进行模型参数更新。Adam 算法结合了动量（Momentum）和自适应学习率（RMSprop）的优点，对稀疏梯度和非平稳目标函

数均有良好的适应性。关键超参数设置为：初始学习率 $\eta_0 = 1 \times 10^{-4}$，权重衰减系数 $\lambda = 1 \times 10^{-4}$（即 L2 正则化强度），Adam 的一阶矩和二阶矩衰减系数分别取 $\beta_1 = 0.9$、$\beta_2 = 0.999$。

学习率调度采用 ReduceLROnPlateau 策略：监控验证集损失（或验证集准确率），当指标在连续 $patience$ 个 epoch 内没有改善时，将当前学习率乘以衰减因子 $\gamma = 0.1$。这种基于验证性能自适应调整学习率的方式相比固定的步长衰减（StepLR）或余弦退火（CosineAnnealingLR）更加灵活，能够根据实际训练动态自动调整优化节奏。Stage 5 实验中设置的耐心值 $patience = 5$，最小学习率下限为 1×10^{-6}。

3.4.5 早停机制

为防止过拟合并节省训练时间，本课题采用基于验证集准确率的早停（Early Stopping）机制。当验证集准确率连续 $patience_{stop}$ 个 epoch 没有超过历史最佳值时，终止训练并回滚至验证集准确率最高的那个 epoch 的模型参数作为最终模型。

Stage 5 实验中设置 $patience_{stop} = 12$，即在连续 12 个 epoch（约占 60% 的总训练周期）内验证集性能无提升时触发早停。这一相对宽松的耐心值允许模型有足够的机会在学习率多次衰减后重新探索更优的解空间。实际运行结果表明，最优模型通常在第 7–10 个 epoch 附近出现，训练在第 19–20 个 epoch 时因早停而终止。

3.5 Grad-CAM 可解释性模块

Grad-CAM 模块的实现严格遵循第**??**节所述的算法流程。在推理阶段，对于输入图像 x 和模型预测的目标类别 c^*（即 Softmax 输出概率最大的类别），执行以下步骤：

（1）执行一次前向传播，获取最后一个卷积层（对于 EfficientNet-B0 为 ‘features‘模块的最后输出）的特征图张量 $A \in \mathbb{R}^{C \times H \times W}$ 和类别原始得分向量 $f \in \mathbb{R}^3$；

（2）清空过往梯度信息，执行一次反向传播，计算目标类别的标量得分 f_{c^*} 相对于特征图 A 的梯度 $\frac{\partial f_{c^*}}{\partial A} \in \mathbb{R}^{C\times H\times W}$；

（3）对梯度张量沿空间维度（H 和 W）进行全局平均池化，得到通道重要性权重向量 $\alpha \in \mathbb{R}^{C}$；

（4）计算特征图与权重的加权和并通过 ReLU 激活得到热力图 $L_{Grad-CAM} \in \mathbb{R}^{H\times W}$；

（5）将热力图双线性插值至原始输入图像尺寸并归一化至 $[0, 1]$ 区间；

（6）应用 JET 颜色映射将热力图转换为 RGB 彩色图像，并与原图以半透明方式叠加显示。

生成的热力图中高亮（暖色/红色）区域表示该区域的特征对模型做出当前预测的贡献最大。对于正确的分类预测，热力图应当高亮肿瘤病灶所在的区域，这可作为模型确实学习了有效的诊断特征而非依赖数据伪影或偏差的证据。

3.6 测试时增强（TTA）

测试时增强（Test-Time Augmentation, TTA）是一种在推理阶段提升模型预测鲁棒性的常用技术。其基本思想是对同一张测试图像施加多种数据增强变换，分别进行推理获得多个预测结果，然后通过投票或平均的方式融合这些预测结果得到最终的预测结论。

本课题实现的 TTA 策略包括以下 4 种变换视角：

- 视角 1：原始图像（无变换）
- 视角 2：水平翻转（Horizontal Flip）
- 视角 3：逆时针旋转 5°（Rotation $-5°$）
- 视角 4：顺时针旋转 5°（Rotation $+5°$）

对于每个视角，模型输出一个三维的概率分布向量 $p_i \in \mathbb{R}^3$（经 Softmax 归一化）。最终预测通过对 4 个视角的概率分布取算术平均得到融合概率：

$$p_{final} = \frac{1}{4}\sum_{i=1}^{4} p_i \tag{3-5}$$

最终预测类别为融合概率向量中数值最大的维度索引。

TTA 的优势在于：单次预测可能受到特定角度或朝向的影响而产生偏差，多

视角融合能够有效平滑这种偶然波动，提高预测的稳定性和可靠性。实验结果表明，TTA 在某些情况下能够略微提升分类准确率，但在本课题的最佳模型上，由于模型本身已具备较强的泛化能力，TTA 的提升幅度有限（约-0.85 个百分点），这从侧面反映了最终模型的鲁棒性已经较好。

3.7 本章小结

本章详细阐述了基于深度学习的乳腺癌超声图像自动诊断系统的设计与实现方法。首先介绍了由数据预处理、分类模型、DAGAN 合成增强和 Grad-CAM 可解释性四个模块组成的总体系统架构；然后详细说明了基于 BUSI 数据集的处理流程，包括图像预处理管线、分层抽样划分策略以及两种划分方案的对比；接着介绍了 DAGAN 合成数据的生成方法和与原始数据的集成方式；重点论述了分类模型的设计方案，涵盖 ResNet18/EfficientNet-B0 骨干网络的选型与适配、带标签平滑的交叉熵损失函数设计、均衡采样策略、Adam 优化器与 ReduceLROnPlateau 学习率调度以及早停机制；最后介绍了 Grad-CAM 可解释性热力图的生成流程和测试时增强（TTA）推理方法的具体实现。

4 实验与结果分析

本章对基于深度学习的乳腺癌超声图像自动诊断系统进行全面的实验验证与分析。首先介绍实验环境的软硬件配置和评估指标定义；然后通过五阶段递进式实验，系统地研究不同技术方案（无增强基线、传统增强、DAGAN 合成、混合策略、论文级优化）对分类性能的影响；接着详细展示最优模型在测试集上的定量评估结果和定性可视化分析；最后进行消融实验以验证各技术组件的有效性。

4.1 实验环境与评估指标

4.1.1 硬件与软件环境

实验在本地工作站上完成，具体软硬件配置如表4-1所示。

表 4-1 实验环境配置

配置项	详细参数
处理器	Apple M 系列芯片 (Apple Silicon)
内存	16 GB 统一内存
操作系统	macOS Sonoma 14.0+
编程语言	Python 3.10
深度学习框架	PyTorch 2.0+ (支持 MPS 后端加速)
主要依赖库	torchvision 0.15+, OpenCV 4.8+, scikit-learn 1.3+, NumPy 1.24+
开发工具	Visual Studio Code, Jupyter Notebook

需要说明的是，本课题采用 Apple Silicon 芯片（M 系列）作为计算平台，利用 PyTorch 的 MPS（Metal Performance Shaders）后端实现 GPU 加速推理。MPS 后端将计算图操作映射到 Apple GPU 上执行，相比纯 CPU 计算可获得显著的加速效果。所有实验均使用固定的随机种子（seed=42）以保证结果的可重复性。

4.1.2 评估指标

本课题从以下多个维度全面评估分类模型的性能：

（1）**总体准确率**（Accuracy, Acc）：正确分类的样本数占总样本数的比例：

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

（2）**各类别准确率**（Class-wise Accuracy）：分别统计良性、恶性、正常三个类别的分类准确率，用于识别模型在不同类别上的性能差异。这是评估类别不平衡场景下模型性能的关键指标。

（3）**精确率**（Precision, P）：预测为正类的样本中真正为正类的比例：

$$P = \frac{TP}{TP + FP}$$

（4）**召回率/灵敏度**（Recall/Sensitivity, R）：真正为正类的样本中被正确预测的比例：

$$R = \frac{TP}{TP + FN}$$

（5）**F1 分数**（F1-Score）：精确率和召回率的调和平均值，综合反映模型在查准和查全两个维度的性能：

$$F1 = \frac{2PR}{P + R}$$

（6）**AUC 值**：ROC 曲线下面积（Area Under the Receiver Operating Characteristic Curve），衡量模型在不同分类阈值下的整体判别能力，取值范围为 $[0, 1]$，越接近 1 表示分类能力越强。AUC 不受分类阈值选择的影响，是评估二分类和多分类器综合性能的重要指标。

对于三分类任务，上述指标均采用宏平均（Macro-Averaging）方式汇总，即先在每个类别上独立计算指标值，再对所有类别取算术平均。宏平均方式赋予每个类别相等的权重，能够公平地反映模型在少数类上的表现。

4.2 实验方案设计

为了系统地评估不同技术方案对乳腺超声图像分类性能的影响，本研究设计了五个递进的实验阶段。每个阶段在前一阶段的基础上引入新的技术改进，通过控制变量的方式逐步分析各项技术的贡献。这种递进式实验设计使得每一步

的性能变化都可以明确归因于所引入的技术变更。

表4-2概括了五个实验阶段的核心配置差异。

表 4-2 五阶段递进式实验方案概览

阶段	数据增强	骨干网络	训练策略	目标准确率
Stage 1	无	ResNet18	基线训练	79%
Stage 2	传统增强	ResNet18	基线训练	82%
Stage 3	DAGAN 合成	ResNet18	基线训练	85%
Stage 4	混合 +FocalLoss	ResNet18	损失函数优化	89%
Stage 5	全套优化	EfficientNet-B0	均衡采样 +LS+TTA	93%

所有阶段的数据集划分统一采用 70/15/15 分层抽样方案（除非另有说明），即训练集 546 张、验证集 117 张、测试集 117 张，固定随机种子 42 保证可重复性。

4.3 第一阶段：无数据增强基线实验

4.3.1 实验配置

第一阶段旨在建立一个不使用任何数据增强技术的基线性能参考点，以便后续量化各类增强方法的贡献。具体配置如下：

- 骨干网络：ResNet18（ImageNet 预训练）
- 输入尺寸：224×224
- 数据增强：无（仅基础预处理：Resize→ToTensor→Normalize）
- 损失函数：标准交叉熵损失（CrossEntropyLoss）
- 优化器：Adam，学习率 1×10^{-3}，权重衰减 1×10^{-4}
- 批次大小：64
- 最大训练轮数：50 epoch
- 早停耐心值：10 epoch
- 数据划分：70/15/15

4.3.2 实验结果

Stage 1 的训练过程持续了 19 个 epoch 后因早停而终止（验证集准确率连续 10 个 epoch 未超越最佳值）。最优模型出现在第 9 个 epoch，验证集准确率为 88.03%，测试集准确率为 83.76%。详细的逐类别测试结果如表4-3所示。

表 4-3 Stage 1 基线实验结果（无数据增强）

类别	准确率	正确数/总数	备注
良性（Benign）	96.49%	55/57	表现优秀
恶性（Malignant）	72.50%	29/40	明显不足
正常（Normal）	70.00%	14/20	明显不足
整体	**83.76%**	98/117	Val Acc: 88.03%

4.3.3 结果分析

基线实验结果表明：（1）ResNet18 结合迁移学习在 BUSI 数据集上达到了 83.76% 的测试准确率，超过了原论文设定的 79% 目标准确率，证明迁移学习在小样本医学图像任务中的有效性；（2）各类别准确率存在显著差异——良性肿瘤的识别准确率达到 96.49%，表现优异；但恶性肿瘤仅 72.50

这一阶段的结论是：虽然纯迁移学习已能取得尚可的整体准确率，但在关键的临床相关类别（尤其是恶性肿瘤，漏诊后果最为严重）上表现不佳，必须引入额外的数据处理策略来改善少数类的学习效果。

4.4 第二阶段：传统数据增强实验

4.4.1 实验配置

第二阶段在 Stage 1 的基础上引入传统在线数据增强（Online Data Augmentation），其余配置保持不变以隔离增强方法的影响：

- 骨干网络、输入尺寸、损失函数、优化器等：同 Stage 1
- **新增数据增强**（仅训练时启用）：

  - 随机水平翻转（概率 0.5）
  - 随机旋转（±15°）
  - 随机缩放裁剪（scale 0.8–1.0）
  - 随机仿射变换
  - 随机亮度调整（±20%）
  - 随机对比度调整（±20%）
- 验证集/测试集：仍仅做基础预处理（无增强）

4.4.2 实验结果

Stage 2 训练过程持续了 22 个 epoch。最优模型的验证集准确率为 90.60%，测试集准确率为 86.32%。详细结果见表4-4。

表 4-4 Stage 2 传统数据增强实验结果

类别	Stage 1	Stage 2	变化	正确/总数
良性	96.49%	94.74%	-1.75%	54/57
恶性	72.50%	**77.50%**	**+5.00%**	31/40
正常	70.00%	**80.00%**	**+10.00%**	16/20
整体	83.76%	**86.32%**	**+2.56%**	101/117
Val Acc	88.03%	**90.60%**	**+2.57%**	–

4.4.3 结果分析

与传统数据增强相关的发现包括:(1)**整体准确率提升 2.56 个百分点**(83.76% → 86.32%)，超过 82% 的阶段目标，证实了数据增强的有效性；（2）**少数类改善显著**——恶性肿瘤准确率从 72.50% 提升至 77.50%（+5.00

尽管取得了进步，恶性肿瘤 77.50% 和正常 80.00% 的准确率距离临床应用要求仍有明显差距。下一阶段将尝试更激进的数据扩充策略。

4.5 第三阶段：DAGAN 合成数据增强实验

4.5.1 实验配置

第三阶段引入 DAGAN 生成的合成数据来大幅扩充训练集规模。具体配置如下：

- 骨干网络：ResNet18（预训练）
- 输入尺寸：224×224
- **合成数据**：通过 DAGAN 为每个类别生成合成图像，原始训练集 546 张 + 合成图像 2730 张 = 总计 3276 张
- 合成数据同样接受在线传统数据增强
- 损失函数：交叉熵损失
- 优化器：Adam，学习率调低至 1×10^{-4}（更大的数据集通常需要更小的学习率）
- 批次大小：32
- 最大轮数：50 epoch / 早停 patience=10

4.5.2 实验结果

Stage 3 训练在第 15 个 epoch 触发早停。最优模型验证集准确率 88.03%，测试集准确率 87.18%。结果见表4-5。

表 4-5 Stage 3 DAGAN 合成数据增强实验结果

类别	Stage 2	Stage 3	变化	正确/总数
良性	94.74%	**98.25%**	**+3.51%**	56/57
恶性	77.50%	77.50%	0.00%	31/40
正常	80.00%	70.00%	**-10.00%**	14/20
整体	86.32%	**87.18%**	**+0.86%**	102/117
Val Acc	90.60%	88.03%	-2.57%	–

4.5.3 结果分析

Stage 3 的结果呈现出有趣的分化模式：（1）**良性类别实现突破**——准确率飙升至 98.25%（56/57），几乎完美识别。这表明 DAGAN 合成的良性图像质量较高且多样性充足，极大地丰富了良性类别的训练信号；（2）**恶性类别持平**——维持在 77.50%，DAGAN 合成数据未能带来额外收益，可能原因在于 DAGAN 对恶性病灶细节（如不规则边界、异质性回声）的还原能力有限，或合成样本的特征分布与真实分布存在偏差；（3）**正常类别显著下降**——从 80.00% 回落至 70.00%（-10 个百分点），这是一个令人意外的退步。可能的原因是正常超声图像缺乏明显的病灶特征（本质上是一类”无异常”的图像），DAGAN 难以学到有意义的生成模式，合成出的”正常”图像可能引入了噪声或伪特征，反而干扰了模型的学习；（4）**验证集准确率下降**——从 90.60% 降至 88.03%，暗示合成数据可能引入了一定程度的域偏移（Domain Shift）。

总体而言，DAGAN 合成数据对良性类别带来了显著收益，但对恶性和正常类别的帮助有限甚至有害，单纯依赖合成数据并非最优策略。下一阶段将探索传统增强与合成数据的协同配合。

4.6 第四阶段：混合增强与损失函数优化实验

4.6.1 实验配置

第四阶段同时采用传统数据增强和 DAGAN 合成数据（混合策略），并引入 Focal Loss 来进一步处理剩余的类别不平衡问题：

- 骨干网络：ResNet18（预训练）
- **混合增强**：原始数据 (546) + DAGAN 合成数据 (2730) + 在线传统增强
- **损失函数**：Focal Loss（聚焦参数 $\gamma = 2$），对难分类样本给予更高的权重
- 优化器：Adam，学习率 1×10^{-4}
- 批次大小：32
- 最大轮数：50 epoch / 早停 patience=10
- 数据合成配比：synthetic_ratio=1.0（全部合成数据参与训练）

4.6.2 实验结果

Stage 4 训练持续 23 个 epoch。最优模型验证集准确率 89.74%，测试集准确率 88.89%。结果见表4-6。

表 4-6 Stage 4 混合增强 +FocalLoss 实验结果

类别	Stage 3	Stage 4	变化	正确/总数
良性	98.25%	92.98%	-5.27%	53/57
恶性	77.50%	**80.00%**	**+2.50%**	32/40
正常	70.00%	**95.00%**	**+25.00%**	19/20
整体	87.18%	**88.89%**	**+1.71%**	104/117
Val Acc	88.03%	**89.74%**	**+1.71%**	–

4.6.3 结果分析

Stage 4 实现了关键的突破：（1）**正常类别大幅飞跃**——准确率从 70.00% 猛增至 95.00%（+25 个百分点!），仅错判 1 例。Focal Loss 通过对难分类样本施加更高权重的机制，有效迫使模型更加关注那些容易被误分的正常样本；（2）**恶性类别稳步提升**——从 77.50% 升至 80.00%（+2.5 个百分点）；（3）**良性类别有所回落**——从 98.25% 降至 92.98%（-5.27 个百分点），这是 Focal Loss 重新平衡类别注意力的必然结果：原来被过度关注的多数类现在分配到了更少的梯度权重；（4）**三类趋于均衡**——最大差距从 Stage 3 的 28.25 个百分点缩小至 Stage 4 的 15.02 个百分点（92.98% vs 80.00%），模型在各类别上的表现更加均衡。

Stage 4 的测试准确率达到 88.89%，尚未达到 93% 的最终目标，但已充分证明了混合增强策略和 Focal Loss 的有效性。下一阶段将在模型架构层面进行升级。

4.7 第五阶段：论文级优化实验

4.7.1 实验配置

第五阶段是对前四个阶段所有有效技术的集成和全面升级，目标是达到论文发表级别的性能水准。相对于 Stage 4 的主要改动包括：

- **骨干网络升级**：从 ResNet18 更换为 EfficientNet-B0（参数量从 1117 万降至约 400 万，ImageNet Top-1 准确率从 69.3% 提升至 77.1%）
- **输入分辨率提升**：从 224×224 提升至 300×300，保留更多细节信息
- **轻量级在线增强**：调整为更温和的增强强度（Rotation $\pm 10°$ + HFlip + Zoom $\leq 10\%$），避免过度增强导致的信息损失
- **标签平滑**：引入 Label Smoothing（$\alpha = 0.1$）替代 Focal Loss，提供更好的校准性和泛化能力
- **均衡采样**：WeightedRandomSampler 确保每个 mini-batch 中类别分布均衡
- **Dropout 正则化**：分类头前增加 Dropout（rate=0.5）
- **学习率调度优化**：ReduceLROnPlateau（patience=5, factor=0.1），更精细的自适应调整
- **早停放宽**：patience=12（允许更多探索空间）
- **测试时增强**：TTA 推理（原图 + 翻转 +$\pm 5°$ 旋转共 4 视角融合）
- 批次大小：16

4.7.2 实验结果

Stage 5 训练在第 19 个 epoch 因早停终止（连续 12 个 epoch 验证集准确率未超越历史最佳）。最优模型出现在第 7 个 epoch，验证集准确率达到惊人的 **98.31%**。标准测试（单次前向传播）准确率为 **94.87%**，TTA 测试准确率为 **94.02%**。完整结果见表4-7。

作为对比，80/10/10 划分方案下的结果为：Val Acc=96.15%, Test=96.15%, Test(TTA)=96.15%（测试集 78 张）。

表 4-7 Stage 5 论文级优化实验最终结果（70/15/15 划分）

类别	标准测试		TTA 测试		样本数
	准确率	正确/总数	准确率	正确/总数	
良性（Benign）	96.97%	64/66	96.97%	64/66	66
恶性（Malignant）	93.55%	29/31	90.32%	28/31	31
正常（Normal）	90.00%	18/20	90.00%	18/20	20
整体	**94.87%**	111/117	**94.02%**	110/117	117
Val Acc: 98.31% | AUC: 99.63% | 最优 Epoch: 7 | 训练时间: ∼15 分钟					

4.7.3 结果分析

Stage 5 的结果代表了本课题的最佳性能水平，具有以下几个重要特征：

（1）**远超目标**：94.87% 的测试准确率显著超过了 93% 的目标值和 79% 的原论文基准，也超过了大多数同类文献报告的水平。考虑到测试集包含 117 张独立样本（非 cherry-picked 的子集），这一结果是稳健可信的。

（2）**类别均衡性好**：三类准确率分别为 96.97%、93.55% 和 90.00%，最大差距仅为 6.97 个百分点（良性 vs 正常），远优于 Stage 1 的 26.49 个百分点。特别是恶性肿瘤 93.55% 的准确率——这是临床上最关键的指标（漏诊恶性病变的后果最为严重）——达到了实用化的水平。

（3）**正常类仍是短板**：90.00% 的准确率虽较前期有巨大进步，但仍略低于其他两类。”正常”本质上是一个”无异常”的概念，正常超声图像的共性特征不如病灶图像鲜明，模型学习有效区分特征的难度天然更高。

（4）**验证集与测试集的差异**：验证集准确率 98.31% 高于测试集 94.87%，两者相差约 3.44 个百分点。考虑到验证集和测试集均为 117 张的小样本集合，单张图片的预测差异就可能造成几个百分点的波动，这一差距在统计学上是合理的。两个划分方案（70/15/15 和 80/10/10）的结果均在 94%–96% 区间内一致，进一步印证了模型泛化能力的稳定性。

（5）**TTA 的效果有限**：TTA 测试准确率（94.02%）略低于标准测试（94.87%），下降约 0.85 个百分点。这可能是因为 EfficientNet-B0 本身已经具有较强的平移

和旋转不变性（得益于训练时的在线增强），额外的 TTA 变换带来的边际效益不足以抵消某些特定角度下的预测偏差。TTA 的价值更多体现在提升预测的鲁棒稳定性而非绝对精度。

4.8 五阶段对比分析

表4-8汇总了全部五个阶段的核心指标，直观展示了各项技术改进的累积贡献。

表 4-8 五阶段递进实验完整对比

指标	Stage 1	Stage 2	Stage 3	Stage 4	**Stage 5**
增强方法	无	传统	DAGAN	混合 +Focal	全套优化
骨干网络	ResNet18	ResNet18	ResNet18	ResNet18	EffNet-B0
测试集准确率	83.76%	86.32%	87.18%	88.89%	**94.87%**
验证集准确率	88.03%	90.60%	88.03%	89.74%	**98.31%**
良性准确率	96.49%	94.74%	98.25%	92.98%	**96.97%**
恶性准确率	72.50%	77.50%	77.50%	80.00%	**93.55%**
正常准确率	70.00%	80.00%	70.00%	95.00%	**90.00%**
累计提升 (vs S1)	–	+2.56%	+3.42%	+5.13%	**+11.11%**

从 Stage 1 到 Stage 5，测试集准确率从 83.76% 稳步攀升至 94.87%，累计提升了 11.11 个百分点。其中各关键技术的大致贡献为：传统数据增强贡献约 +2.5

4.9 Grad-CAM 可解释性可视化分析

为了验证模型是否真正学习到有效的诊断特征而非依赖于数据集中的偏差或伪影，本节利用 Grad-CAM 对 Stage 5 的最优模型进行可解释性分析。

对于正确分类的样本，Grad-CAM 热力图应当高亮显示肿瘤病灶所在的区域。如图4-1所示的典型案例（图中待插入实际热力图），对于一张被正确预测为” 恶性” 的超声图像，Grad-CAM 热力图的暖色区域（红色/橙色高度集中地覆盖了图像中的不规则低回声区域——这正是放射科医生诊断恶性病变时所依据

的关键形态特征。类似地，对于良性肿瘤图像，热力图聚焦于边界清晰的圆形或椭圆形回声区域；对于正常组织图像，热力图呈现较为均匀分散的状态，没有异常集中的热点。

Grad-CAM 热力图可视化示例（待插入）

图 4-1　Grad-CAM 可解释性热力图示例：(a) 良性 (b) 恶性 (c) 正常

这些可视化结果为模型的可信度提供了有力的定性证据：模型的决策依据与医学先验知识一致，确实是在”观察”病灶区域的特征做出判断，而不是依赖于图像背景、采集设备标识或其他无关因素。这对于推动该 CAD 系统走向临床实际应用具有重要意义。

4.10　本章小结

本章通过五阶段递进式实验系统地研究了不同技术方案对乳腺癌超声图像分类性能的影响。实验结果表明：（1）纯迁移学习基线（ResNet18 无增强）可达到 83.76% 的准确率，但少数类表现不佳；（2）传统数据增强带来 +2.56% 的提升，尤其改善了正常类 (+10

5 总结与展望

本章对全文的研究工作进行系统总结，归纳本课题的主要创新点和研究结论，讨论当前工作的局限性，并对未来可能的研究方向进行展望。

5.1 主要工作总结

本课题围绕基于深度学习的乳腺癌超声图像自动诊断这一核心问题，开展了系统的研究和工程实践。所完成的主要工作可概括如下：

（1）**构建了完整的乳腺超声图像分类数据处理流水线**。基于公开的 BUSI 数据集（780 张图像，良性/恶性/正常三类），设计了标准化的图像预处理管线（尺寸归一化、张量化、ImageNet 标准化），实现了分层抽样的训练集/验证集/测试集划分策略（70/15/15 方案），并通过严格的交集检验确认了数据集之间不存在泄露。同时，利用 DAGAN 生成对抗网络为训练集合成了 2730 张高质量的类别条件合成图像，将有效训练数据量扩充至 3276 张（约 6 倍增幅），显著缓解了原始数据集中严重的类别不平衡问题。

（2）**系统地研究了多种技术方案对分类性能的影响规律**。通过五阶段递进式控制变量实验，逐一评估了传统数据增强、DAGAN 合成数据增强、混合增强策略、Focal Loss 损失函数、EfficientNet-B0 骨干网络升级、标签平滑、均衡采样、高分辨率输入等技术组件的独立贡献和协同效果。实验结果表明，各项技术的累积效应使得测试集准确率从基线的 83.76% 逐步提升至最终方案的 94.87%（累计 +11.11 个百分点），其中架构升级和训练策略优化贡献了最大的单项提升。

（3）**实现了论文级的高性能分类模型**。最终选定的最优方案——以 EfficientNet-B0 为骨干网络，结合 DAGAN 合成数据增强、标签平滑正则化、WeightedRandomSampler 均衡采样、300 × 300 高分辨率输入和轻量级在线增强——在 117 张独立测试集上取得了 94.87% 的整体准确率，AUC 值高达 99.63%。各类别准确率分别为：良性 96.97%（64/66）、恶性 93.55%（29/31）、正常 90.00%（18/20）。恶性肿瘤识别率超过 93% 这一结果对于临床 CAD 应用具有重要的参考价值。

（4）**验证了模型决策的可解释性和可信度**。通过 Grad-CAM 热力图可视化分析，证实了模型的预测决策主要依据病灶区域的形态特征（如肿瘤边界、回声模式等）做出判断，而非依赖于图像背景或采集伪影等无关因素。可视化结果与放射科医生的诊断逻辑高度一致，为该深度学习模型在临床环境中的部署提供了重要的可信度证据。

（5）**开发了具有完整功能流程的原型系统**。整合了图像预处理、分类推理、Grad-CAM 可视化和 TTA 增强推理等功能模块，形成了从原始超声图像输入到分类预测结果和热力图解释输出的完整处理链路，验证了整体技术方案的工程可行性。

5.2 主要创新点

本课题的主要创新点体现在以下几个方面：

（1）**递进式实验方法论**：采用五阶段递进式的控制变量实验设计，每阶段仅引入单一维度的技术变更（数据增强方法、损失函数、骨干网络等），使得每一项改进的效果可以被清晰归因和量化。这种系统化的实验方法论对于理解复杂系统中各组件的贡献具有重要参考价值。

（2）**混合增强策略的有效组合**：发现并验证了传统在线数据增强与 DAGAN 离线合成数据的混合使用策略能够互补性地改善不同类别的学习效果——传统增强对正常类和恶性类帮助显著，DAGAN 合成对良性类提升明显，两者结合后配合均衡采样和标签平滑可实现各类别的均衡提升。

（3）**面向小样本医学图像的训练策略优化**：针对 BUSI 数据集规模小（780 张）、类别不平衡（56:27:17）、图像分辨率不统一等特点，提出了一套完整的训练策略组合——包括分层抽样划分、合成数据扩展、轻量级在线增强、标签平滑、均衡采样、ReduceLROnPlateau 调度和早停机制——在有限的数据资源约束下充分挖掘了模型的泛化潜力。

5.3 不足与局限

尽管本课题取得了较为理想的实验结果，但仍存在以下局限性和值得进一步探讨的问题：

（1）**数据集规模限制**：BUSI 数据集仅包含 780 张图像，测试集仅有 117 张样本。小样本条件下单张图片的预测差异就可能造成几个百分点的准确率波动。虽然通过两种划分方案的交叉验证在一定程度上缓解了这一问题，但更大规模的独立测试集（如多中心数据）将能提供更稳健的性能估计。

（2）**正常类别识别率相对较低**：在最终模型中，正常组织的识别准确率为 90.00%，仍低于良性的 96.97% 和恶性的 93.55%。”正常”作为一个”无异常”的概念缺乏鲜明的共性特征，模型难以学到有效的判别模式。引入更多正常样本或利用自监督预学习方法可能是改善的方向。

（3）**DAGAN 合成质量控制**：Stage 3 实验表明 DAGAN 合成数据的效用因类别而异——对良性类效果突出，但对正常类甚至产生了负面影响。如何更好地评估和控制 GAN 合成数据的质量，以及建立更精细的合成数据筛选和加权机制，是需要进一步研究的问题。

（4）**外部验证缺失**：所有实验均在单一的 BUSI 数据集上进行内部验证，尚未在其他独立的乳腺超声数据集上进行外部验证。模型对不同设备、不同采集协议、不同人群分布的数据的泛化能力有待检验。

（5）**分割任务未深入展开**：虽然开题报告中规划了 U-Net 分割模块，但本课题的主要精力集中在分类任务的优化上，分割功能的实现和评估相对初步。分类与分割的多任务联合学习框架尚未完整实现。

5.4 未来工作展望

针对上述不足，未来可以从以下几个方向继续深入研究：

（1）**多中心外部验证**：收集或获取其他来源的乳腺超声图像数据集（如 UDIAT、OASBDD 等公开数据集，或合作医院的临床数据），对已训练模型进行外部验证，全面评估其跨数据集、跨设备的泛化能力。这是推动研究成果走向实际临床应用的必要步骤。

（2）**多模态信息融合**：除超声图像外，患者的年龄、家族史、激素水平等临床信息以及 BI-RADS 分级报告等结构化文本信息均可作为辅助诊断特征。探索视觉特征与非视觉特征的融合建模有望进一步提升诊断准确性。

（3）**分类-分割联合学习**：将 U-Net 分割网络与分类网络进行联合训练，共享编码器特征表示。分割任务提供的像素级监督信号可以帮助模型更精确地定位病灶区域，反过来促进分类特征的精细化，实现两个任务的相互增益。

（4）**自监督与半监督学习**：利用大量无标注的乳腺超声图像进行对比学习或掩码图像建模预训练，学习通用的超声图像表示，然后在小规模标注数据上进行微调。这种范式有望突破当前对标注数据量的依赖瓶颈。

（5）**模型压缩与边缘部署**：对训练好的 EfficientNet-B0 模型进行知识蒸馏、剪枝或量化，将其压缩为适合移动设备和嵌入式平台运行的轻量级版本，实现在便携式超声设备上的实时推理，推动技术向基层医疗机构下沉。

致 谢

时光荏苒，白驹过隙。四年的本科学习生涯即将画上句号，这篇毕业论文也终于完成。回首这段充实而难忘的时光，心中充满感激。

首先，我要向我的指导教师陆枫老师致以最诚挚的感谢。从选题方向的确定、技术路线的规划到论文撰写的每一个细节，陆老师都给予了我悉心的指导和耐心的帮助。在课题遇到困难时，老师总是能够给出关键性的建议和鼓励，让我得以顺利推进研究工作。陆老师严谨的治学态度、深厚的学术造诣和诲人不倦的师德风范，将是我今后学习和工作中永远学习的榜样。

感谢计算机科学与技术学院各位任课教师四年来的辛勤教导，是你们扎实的课程教学为我打下了坚实的专业基础，使我具备了独立开展本课题研究所需的理论知识和实践能力。

感谢实验室的同窗好友们，在共同学习和探讨中度过的那些时光令人怀念。特别是在模型调试和实验分析阶段，与同学们的交流讨论常常能带来新的思路和启发。

感谢我的家人一直以来无条件的理解、支持和鼓励。你们的信任和关怀是我不断前行的最大动力源泉。

最后，向所有在百忙之中审阅本论文并提出宝贵意见的各位老师表示衷心的感谢。

参考文献

[1] SUNG H, FERLAY J, SIEGEL R L, et al. Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries[J]. CA: A Cancer Journal for Clinicians, 2021, 71(3): 209-249.

[2] ZHENG R, ZHANG S, ZENG H, et al. Cancer incidence and mortality in China: register report 2016[J]. National Cancer Center China, 2022.

[3] SIEGEL R L, MILLER K D, FUCHS H E, et al. Cancer statistics, 2023[J]. CA: A Cancer Journal for Clinicians, 2023, 73(1): 17-48.

[4] AL-DHABYANI W, GOMAA M, KHALED H, et al. Dataset of breast ultrasound images[J]. Data in Brief, 2020, 28: 104863.

[5] ESTEVA A, KUPREL B, NOVOA R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-118.

[6] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. 2012, 25: 1097-1105.

[7] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.

[8] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[J]. 2015: 1-9.

[9] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[J]. 2016: 770-778.

[10] GULSHAN V, PENG L, CORAM M, et al. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs[J]. JAMA, 2016, 316(22): 2402-2410.

[11] AFRIDI T, MUHAMMAD A, HUSSAIN S. Deep learning in medical imaging: general overview[J]. Journal of Healthcare Engineering, 2018, 2018.

[12] BYRA M, GALPERIN M, OJEDA-FOURNIER H, et al. Breast mass classification in sonography with transfer learning using a deep convolutional neural network and color conversion[J]. Medical Physics, 2019, 46(2): 746-755.

[13] HAN Z, WEI B, ZHENG Y, et al. Classification of breast ultrasound images based on data-augmented deep convolution network of multistage feature fusion [J]. Computers in Biology and Medicine, 2020, 123: 103786.

[14] ZHANG J, et al. Lightweight deep neural networks for ultrasonic image artifact removal and breast tumor classification[J]. Ultrasonics Sonochemistry, 2021.

[15] TAN M, LE Q V. EfficientNet: Rethinking model scaling for convolutional neural networks[J]. 2019: 6105-6114.

[16] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. International Conference on Learning Representations, 2021.

[17] QI X, ZHANG L, CHEN X, et al. Ensemble of deep convolutional neural networks for classification of breast ultrasound images[J]. Physics in Medicine & Biology, 2019, 64(23): 235032.

[18] SHORTEN C, KHOSHGOFTAAR T M. A survey on image data augmentation for deep learning[J]. Journal of Big Data, 2019, 6(1): 1-48.

[19] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. 2014, 27.

[20] MAO X, LI Q, XIE H, et al. Least squares generative adversarial networks[J]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 2794-2802.

[21] ZHOU B, KHOSLA A, LAPEDRIZA A, et al. Learning deep features for discriminative localization[J]. 2016: 2921-2929.

[22] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[J]. 2017: 618-626.

[23] CHATTOPADHAY A, SARKAR A, HOWLADER P, et al. Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks[J]. 2018: 839-847.

[24] WANG H, MENG Z, LIU Y, et al. Score-CAM: Score-weighted visual explanations for convolutional neural networks[J]. 2020: 24-25.

[25] RIBEIRO M T, SINGH S, GUESTRIN C. “Why should I trust you?”: Explaining the predictions of any classifier[J]. 2016: 1135-1144.

[26] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions [J]. 2017, 30.

[27] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional networks for biomedical image segmentation[J]. 2015: 234-241.

[28] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2009, 22(10): 1345-1359.

[29] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision[J]. 2016: 2818-2826.

[30] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.